

도착 시각(release time)과 soft due date를 갖는 컴파운드 트럭 크로스도킹 스케줄링: CP-SAT로 검증한 병목 유도 Iterated Local Search

김영수* 권상진†

연세대학교 인공지능학과, 서울

Abstract

컴파운드 트럭(compound truck)이 부분 하역된 뒤 특정 목적지의 출고 트럭으로 전환되는 다중 도어 크로스도킹 스케줄링 문제를 다룬다. 기존 컴파운드 트럭 모델은 모든 트럭이 시각 0에 도착한다고 가정하고 총 작업완료시간(makespan)만 최소화한다. 본 연구는 트럭별 도착 시각(release time)과, 위반을 허용하되 지연 비용을 부과하는 soft due date를 도입하고, makespan과 총 납기지연(tardiness)의 합을 최소화하는 문제로 확장한다. 문제를 mixed-integer program과 CP-SAT 모형으로 정식화하고, 서로 겹치지 않는 train, tuning, test seed 집합을 사용한 재현 가능한 실험 프로토콜을 제시한다. 제안 방법인 VAA-GILS는 Vogel식 구성 기법으로 생성한 초기해에 best-improvement descent, 병목(bottleneck) 유도 연산자, 그리고 kick restart를 결합한 iterated local search이다. CP-SAT가 기준해를 제공한 실험 조건에서 VAA-GILS는 그 기준해 대비 평균 0.11–0.21%의 목적값을 1초 미만에 얻었다(CP-SAT는 76–237초). 이 가운데 소형 무제약 조건은 CP-SAT가 최적성을 증명한 경우로, 제안 방법은 증명된 최적해 대비 평균 0.21%였다. CP-SAT가 600초 이내에 실행 가능한 해를 찾지 못한 대형 시간 제약 조건에서도, 제안 방법은 비교 방법 가운데 가장 우수한 해를 제공하였다. Ablation 실험 결과, 성능 향상에는 descent, 병목 유도 연산자, restart로 구성된 결정론적 탐색 구조가 주요하게 기여한 것으로 나타났다. 한편 학습 기반 연산자 선택은 동일 예산의 균등 선택 대비 추가 이득을 보이지 않았다.

주제어: cross-docking; compound truck; release time; soft due date; iterated local search; constraint programming; guided local search

1. 서론

크로스도킹은 입고 화물을 창고에 보관하지 않고 곧바로 출고 트럭으로 환적하여 재고와 리드타임을 줄이는 물류 방식이다 [3, 13]. Joo와 Kim [4]이 도입하고 Shahmardan과 Sajadieh [12]가 발전시킨 컴파운드 트럭 변형에서는 한 대의 트럭이 두 역할을 겸한다. 여러 목적지 화물을 싣고 도착한 뒤 한 목적지의 화물은 유지하고 나머지만 **부분적으로** 하역하며, 이후 해당 목적지의 나머지 화물을 적재해 출고 운송 트럭으로 출발한다. 부분 하역은 전량 하역 대비 makespan을 크게 줄이는 것으로 보고되어 LTL 통합 네트워크에서 실용적 매력이 크다.

기존 컴파운드 트럭 모델의 두 가정이 현실성을 제약한다. 첫째, 모든 트럭이 시각 0에 가용하다고 가정하지만 실제 도크에서는 트럭마다 예약 도착 시각이 다르다. 둘째, 목적함수가 순수 makespan이지만 출고 트럭의 출발은 위반 시 비용이 발생하는 due date에 묶여 있다.

도착 시각(release time), 시간창(time window), 납기지연(tardiness)은 일반 크로스도킹 스케줄링에서 이미 연구되어 왔다 [14, 1, 2, 10, 11, 9]. 그러나 컴파운드 트럭 설정은 temporal constraint의 의미를 바꾼다. 컴파운드 트럭은 순수 입고 트럭도 출고 트럭도 아니다. 부분 하역 후 한 목적지의 화물을 유지하고, 해당 목적지로 들어오는 이송 화물을 기다린 뒤 비로소 출고 운송 트럭으로 출발한다. 이 부분 하역 변환은 하나의 precedence chain — 도착 → 부분 하역 → 유지 화물 → 이송 대기 → 출고 — 을 만들고, 이 chain

*제1저자.

†교신저자. Email: [지도교수 이메일 기입].

은 트럭들을 공유 목적지를 통해 결합한다. 따라서 release time을 추가한다고 해서 한 트럭의 시작 시간만 늦어지는 것은 아니다. 늦은 도착은 해당 트럭의 이송 화물에 의존하는 모든 출고 운송 트럭으로 전파되고, soft due date는 이 연쇄 지연을 tardiness 비용으로 바꾼다. 본 연구의 기여는 이 상호작용 — 알려진 release time과 soft due date가 부분 하역 후 출고 운송 트럭으로 전환되는 과정과 결합되는 방식 — 을 정식화하고 분석하는 것이며, 저자가 아는 한 이 결합은 이전에 모형화된 바 없다.

본 논문의 기여는 세 가지다. 첫째, 부분 하역 컴파운드 트럭 스케줄링을 트럭별 release time과 soft due date를 갖는 문제로 확장하고, 이를 독립적인 스케줄 평가기와 일치하는 big- M MILP 및 reified CP-SAT로 정식화한다. 둘째, 기존 VAA construction과 generic neighborhood에 full best-improvement descent, 병목 유도 연산자, kick restart를 더한 VAA-GILS를 제안한다. 셋째, CP-SAT 기준해와 기존 방법과의 비교실험을 통해 제안 방법의 해 품질과 계산 시간을 검증한다. 이와 별도로, 학습 기반 연산자 선택의 추가 효과는 동일 예산의 균등 선택과 비교하는 보조적인 ablation으로 검토한다.

2. 관련 연구

시간 제약이 있는 크로스도킹 스케줄링. Boysen과 Fließner [3]는 도크 스케줄링 문제를 분류하였고, Van Belle 등 [13]은 분야를 조망하였다. 여러 결정론적 모형이 기존 입고·출고 트럭에 대해 시간 제약을 이미 반영한다. Van Belle 등 [14]은 다중 도어·time window·tardiness를, Assadi와 Bagheri [1]는 ready time과 outbound earliness/tardiness를, Bodnar 등 [2]은 time window와 mixed-service door를 다룬다. Molavi 등 [10]은 hard due date를, Rijal 등 [11]은 truck scheduling과 door assignment의 통합을 다룬다. 이들은 release/due date가 새롭지 않음을 보이나, 입고·출고 트럭을 구분하며 부분 하역 후 출고 운송 트럭으로 전환되는 트럭을 모형화하지 않는다.

불확실·불완전 도착 정보. 도착 불확실성은 별도의 흐름이다. Konur와 Golias는 bounded arrival window [5]와 unknown arrival 하의 cost-stable schedule [6]을 다룬다. Larbi 등 [8]은 도착 정보의 full/partial/absent를 구분하고, Ladier와 Alpan [7]은 time window 하의 robust schedule을, Xi 등 [17]은 two-stage conflict robust optimization을 제시한다. 본 모형은 결정론적이며 각 release time은 스케줄 구성 시점에 알려져 있다. 따라서 이들 불확실성 모형은 본 모형을 직접 대체하기보다 향후 자연스럽게 확장할 수 있는 연구 방향에 해당한다.

가장 유사한 문제와 학습형 메타휴리스틱. Li 등 [9]은 무인 배송센터(distribution center)를 대상으로 mixed service mode dock의 통합 트럭 배정·스케줄링을 Q-learning 기반 ALNS로 푼다. 이들 역시 도착 시간과 연장 가능한 출발 예정 시간을 시간창(r_i, d_i)로 두고 tardiness와 makespan을 목적에 포함하므로, 시간 제약의 형태 자체는 본 연구와 유사하다. 그러나 유연성이 도어 수준에 있어 도어가 적재 전용·하역 전용·혼합 모드 중 하나를 선택하고 트럭은 순수 입고·출고 트럭으로 고정되며, 화물은 도어 간 직접 이송이 아니라 저장 구역을 경유해 AGV가 운반한다. 반면 본 문제의 유연성은 트럭 수준에 있어, 부분 하역된 컴파운드 트럭이 특정 목적지의 운송 트럭으로 전환되고 화물은 도어 간에 직접 이송된다. 한편 이들을 포함하여 학습 기반 operator selection이 메타휴리스틱을 개선한다는 보고가 많으나, 본 연구는 강한 지역 탐색을 갖춘 뒤에는 learned selector의 이득이 작다는 통제된 반례를 더한다.

3. 문제 정의

3.1 기본 모델

I, F, D, K, M 을 각각 컴파운드 트럭, 출고 트럭, 목적지, 상품 종류, 도어의 집합이라 하고 $|I| + |F| = |D|$, $|I| \leq |M|$ 이라 하자. 컴파운드 트럭 i 는 목적지 d 행 상품 k 를 f_{idk} 단위 싣는다. 단위 처리시간 t_k , 도어 m, n 간 배치 이송시간 t_{mn} , 트럭 i 의 진입·출차 전환시간 DE_i, DL_i 에 대해 $h_{id} = \sum_k f_{idk} t_k$, $H_i = \sum_d h_{id}$ 로 둔다. 각 컴파운드 트럭은 유지할 목적지 하나와 도어 하나를(도어당 컴파운드 최대 1대), 각 출고 트럭은 남은 목적지 하나와 도어를 고르며, 같은 도어의 출고 트럭은 작업 순서를 정한다. 각 목적지에는 정확히 하나의 운송 트럭이 배정된다.

각 트럭 $q \in I \cup F$ 의 release time을 r_q 로 나타낸다. 따라서 r_i 는 컴파운드 트럭 $i \in I$ 가 도어 작업을 시작할 수 있는 가장 이른 시각이고, r_f 는 출고 트럭 $f \in F$ 가 도어 작업을 시작할 수 있는 가장 이른 시각이다. 위반이 허용되는 soft due date $\bar{d}_q$ 와 그에 따른 납기 지연 T_q 는 3.3절에서 정의한다.

시간 계산은 스케줄 평가기 규칙을 따른다. 컴파운드 트럭 i (목적지 d 유지)의 하역은 $r_i + DE_i + \sum_{d' \neq d} h_{id'}$ 에 끝난다. 운송 트럭은 화물을 보내는 모든 트럭의 하역과 도어 간 이송이 끝나야 적재할 수 있다. 출고 운송 트럭 f 는 추가로 자신의 release와 도어의 선행 점유가 끝나는 시점에 도어 작업을 시작하여 $S_f = \max(\text{door available, destination ready, } r_f)$ 이며, 이후 진입(DE_f), 적재, 출차(DL_f)를 차례로 수행하므로 완료 시각은 $S_f + DE_f + L_d + DL_f$ 이다. 즉 S_f 는 적재 시작이 아니라 도어 작업 시작 시각이고, 적재는 $S_f + DE_f$ 에 시작한다. makespan $\tau = C_{\max}$ 는 최대 완료 시각이다.

3.2 Mixed-integer 정식화

이진 변수 x_{idm} 은 컴파운드 트럭 $i \in I$ 를 유지 목적지 d ·도어 m 에, $z_{f dm}$ 은 출고 트럭 $f \in F$ 를 배정한다. $X_{im} = \sum_d x_{idm}$, $Z_{fm} = \sum_d z_{f dm}$, $Z_{fd} = \sum_m z_{f dm}$ 로 두고, b_{fgm} 은 도어 m 에서 f 가 g 에 선행하면 1이다. 연속 변수 $U_i, C_i, S_f, C_f, C_{\max}$ 는 각각 컴파운드 하역 완료, 컴파운드 완료, 출고 도어 작업 시작, 출고 완료, makespan이다. $L_{id} = \sum_{j \neq i} h_{jd}$, $L_d = \sum_i h_{id}$, B 는 유효한 horizon 상한이다.

배정 제약은 다음과 같다.

$$\sum_{d,m} x_{idm} = 1 \quad \forall i \quad (1)$$

$$\sum_{d,m} z_{f dm} = 1 \quad \forall f \quad (2)$$

$$\sum_{i,m} x_{idm} + \sum_{f,m} z_{f dm} = 1 \quad \forall d \quad (3)$$

$$\sum_{i,d} x_{idm} \leq 1 \quad \forall m \quad (4)$$

컴파운드 트럭의 시간 관계와 유입 이송 선행 제약은 다음과 같다.

$$U_i = r_i + DE_i + H_i - \sum_{d,m} h_{id} x_{idm} \quad \forall i \quad (5)$$

$$C_i \geq U_i + L_{id} + DL_i - B(1 - x_{idm}) \quad \forall i, d, m \quad (6)$$

$$C_i \geq U_j + t_{nm} + L_{id} + DL_i - B(2 - x_{idm} - X_{jn}) \quad (7)$$

식 (7)은 모든 i, d, m, n 과 $\sum_k f_{j dk} > 0$ 인 기여 트럭 $j \neq i$ 에 대해 성립한다.

출고 운송 트럭에 대해서는 다음이 성립한다.

$$S_f \geq r_f \quad \forall f \quad (8)$$

$$C_f \geq S_f + DE_f + L_d + DL_f - B(1 - Z_{fd}) \quad \forall f, d \quad (9)$$

$$S_f \geq U_i + t_{nm} - B(2 - z_{f dm} - X_{in}) \quad (10)$$

$$S_f \geq C_i - B(2 - Z_{fm} - X_{im}) \quad \forall f, i, m \quad (11)$$

같은 도어 m 을 쓰는 출고 트럭 쌍 $f < g$ 에 대한 순서 결정과 non-overlap 제약은 다음과 같다.

$$b_{fgm} + b_{gfm} \geq Z_{fm} + Z_{gm} - 1, \quad b_{fgm} \leq Z_{fm}, \quad b_{gfm} \leq Z_{gm} \quad (12)$$

$$S_g \geq C_f - B(1 - b_{fgm}) \quad (13)$$

$$S_f \geq C_g - B(1 - b_{gfm}) \quad (14)$$

끝으로 makespan은 다음으로 정의된다.

$$C_{\max} \geq C_i \quad \forall i, \quad C_{\max} \geq C_f \quad \forall f \quad (15)$$

CP-SAT 모형은 big- M disjunction을 enforcement literal로 대체하고 모든 시간값을 가장 가까운 0.01 단위로 반올림한 뒤 100배하여 정수로 변환하며, 모든 배정을 고정하면 독립 evaluator의 완료 시각이 재현되어 model fidelity가 확인된다.

3.3 시간 제약 확장과 목적함수

각 트럭 $q \in I \cup F$ 는 앞서 정의한 release time $r_q \geq 0$ 과 soft due date $\bar{d}_q$ 를 갖고 $T_q \geq \max\{0, C_q - \bar{d}_q\}$ 이다. 목적함수는

$$\min J = C_{\max} + \lambda \sum_{q \in I \cup F} T_q, \quad \lambda = 1 \quad (16)$$

$r_q = 0, \bar{d}_q = \infty$ 이면 기존 makespan 모델로 환원된다. CP-SAT는 incumbent와 증명된 하한을 함께 반환하며, 하한과 일치가 증명될 때에만 최적으로 부른다.

3.4 조합적 하한

CP-SAT가 제공하는 하한이 약한 실험 조건에서 gap을 보고하기 위해 도어 경합을 완화한 두 유효 하한을 사용한다. 컴파운드 트럭 i (목적지 d 유지)의 최속 완료와 출고 트럭 f 의 최속 완료는

$$EF_i = r_i + DE_i + \min_{d \in D} \left(H_i - h_{id} + \sum_{j \in I \setminus \{i\}} h_{jd} \right) + DL_i \quad (17)$$

$$EF_f = r_f + DE_f + \min_{d \in D} \sum_{j \in I} h_{jd} + DL_f \quad (18)$$

critical-chain 하한은 $LB_{cc} = \max_{q \in I \cup F} EF_q$ 이다. door-area 하한은 각 트럭의 최소 도어 점유

$$o_i = DE_i + \left(H_i - \max_d h_{id} \right) + \min_d \sum_{j \in I \setminus \{i\}} h_{jd} + DL_i \quad (19)$$

$$o_f = DE_f + \min_d \sum_{j \in I} h_{jd} + DL_f \quad (20)$$

을 도어 수로 나눈 값이다.

$$LB_{da} = \frac{1}{|M|} \left(\sum_i o_i + \sum_f o_f \right) \quad (21)$$

두 하한 모두 제약을 완화하여 얻으므로 이들의 최댓값 $LB_\tau = \max\{LB_{cc}, LB_{da}\}$ 는 makespan의 유효 하한이다. 또한 각 EF_q 가 C_q 의 하한이므로 구조적 지연 하한은

$$LB_T = \sum_{q: \bar{d}_q < \infty} \max\{0, EF_q - \bar{d}_q\} \quad (22)$$

이며, $LB_J = LB_\tau + \lambda LB_T$ 는 식 (16)의 유효 하한이다.

4. VAA-GILS

VAA-GILS는 iterated local search의 구현체로, 연산자 내부 sampling과 acceptance를 제외하면 결정론적이다. 이하에서 원 모델은 Shahmardan과 Sajadieh [12]가 제안한 SA-RL5를 가리키며, VAA 구성 휴리스틱과 generic 이웃 7종은 이 모델에서 가져왔다.

초기해 구성. 원 모델의 VAA는 Vogel식 regret으로 컴파운드 트럭의 유지 목적지를 정하고, 완료 시각 우선순위에 따라 출고 목적지를 배정한다. 도어 배정은 먼저 처리되는 트럭을 도어 간 이송시간 합이 가장

작은 중앙 도어에 두고, 나머지 트럭은 작업 종료가 가장 이른 도어에 차례로 삽입한다. 모든 완료 예정 시각 계산에는 release time을 반영한다.

Descent. 세 가지 이동 유형(출고 트럭 재배치, 컴파운드 트럭의 도어 교환/빈 도어 이동, 두 트럭의 목적지 교환)에 대한 best-improvement 지역탐색으로, local optimum에서 종료하며 초기해·모든 신규 incumbent·최종해에 적용한다.

반복 탐색. 1,000회 반복한다. 선택 정책이 연산자 하나를 뽑아 현재 해에서 후보를 생성하고, 후보가 전역 최선해를 개선하면 descent를 적용해 incumbent를 갱신한다. acceptance는 초기 온도 $T_0 = \max\{1, 0.05 J(s_0)\}$, 기하 냉각 $T \leftarrow 0.995 T$ 의 simulated annealing이다.

Kick restart와 reheating. 30회 연속 개선이 없으면 kick restart를 수행한다. 현재 최선해 s^* 의 복사본에서 다시 시작하되, 아래 generic 이웃 7종에서 균등 무작위로 뽑은 이동(kick)을 3회 연속 적용한다. 각 이동은 직전 이동의 결과에 적용되며, 재시작 직후에는 descent를 수행하지 않는다. 이어서 $T \leftarrow \max\{T, 0.02 J(s^*)\}$ 로 온도를 reheat한다.

Operator pool. generic 이웃 7종은 원 모델의 이웃 구조를 그대로 사용한다: (k1) 두 트럭의 목적지 교환, (k2) 컴파운드 트럭 간 도어 교환, (k3) 출고 트럭 간 도어 교환, (k4) 출고 트럭을 다른 도어로 삽입, (k6) 하역시간 기반 룰렛 선택으로 컴파운드 트럭을 도어에 삽입, (k7) 적재시간 기반 룰렛 선택으로 출고 트럭을 도어에 삽입, (k8) 룰렛 선택으로 컴파운드 트럭에 목적지를 배정. 원 모델은 이동을 k1-k8로 번호매기나 k5는 정의하지 않아 실제 구현은 7종이다. 여기에 현재 병목을 먼저 식별한 뒤 그 주변에서 가능한 후보를 모두 평가해 최선을 택하는 guided 연산자 4종을 더한다: (g1) critical door의 마지막 출고 트럭을 최선 도어·위치로 재배치, (g2) critical 트럭의 목적지를 전 트럭과 대조해 최선 교환, (g3)/(g4) most tardy 트럭 기준의 동일 이동(tardy인 트럭이 없으면 g1/g2로 fallback). 고속 증분 evaluator(평가당 수십 μs)가 descent와 guided 이동을 저렴하게 만든다.

선택 정책과 원 모델의 비교. 선택 정책은 교체할 수 있으며 기본값은 균등 무작위 선택이다. 학습 정책(SA-RL5의 tabular Q-learning [15], 규모 불변 특징(feature)으로 오프라인 학습한 transfer DQN [16])은 ablation 목적으로만 평가하며 제안 방법의 일부가 아니다. tabular Q는 원 모델과 같이 무개선 구간 5-상태에서 ϵ -greedy 탐험과 룰렛 활용을 쓰되, 보상은 원 모델의 이진 보상(후보가 현재 해보다 나쁘지 않으면 1, 아니면 0) 대신 신규 incumbent 2·비악화 1·그 외 0의 세이핑 보상을 사용한다. 이는 학습 신호를 강화할 뿐이므로 비교 대상 selector를 불리하게 만들지 않는다. 원 모델 SA-RL5는 RL이 단일 이동을 고르고 SA accept/reject로 한 단계가 끝나는 순수 simulated annealing인 반면, VAA-GILS는 그 한 연산자 적용 단계를 iterated local search 안에 넣고 guided 연산자, 개선 이동마다의 full descent, kick restart를 더한다. 가장 중요한 차이는 개선 이동 이후의 descent이며, ablation은 이것이 품질 이득의 대부분을 설명함을 보인다. 표 1가 두 방법의 구조적 차이를 요약한다.

Table 1: 원 모델 SA-RL5와 VAA-GILS의 구조 비교.

항목	SA-RL5 (base)	VAA-GILS (제안)
전체 틀	순수 simulated annealing	iterated local search (SA는 acceptance만)
반복당 연산자	1개	1개 (동일)
연산자 집합	이웃 7종	그 7종 + guided 4종
연산자 선택	online Q-learning/roulette	uniform random (학습은 ablation 전용)
개선 이동 이후	없음(SA step이 전부)	full best-improvement descent
정책 처리	없음	kick restart + reheat
acceptance	SA(Metropolis)	SA(Metropolis; ablation상 생략 가능)
목적함수	makespan	makespan + λ ·tardiness

5. 실험 설계

세 규모 ($|I|, |D|, |M|$): S (6, 9, 6), M (12, 18, 12), L (20, 30, 20), 컴파운드 비율 2/3을 사용한다. flow는 상품 3종에 대해 $[0, 20]$ 의 균등 정수, $t_k \sim U[1, 5]$, 도어는 100×100 랜덤 배치이다. 시간 제약 수준은 none/medium/tight이며 medium/tight에서 $r \sim U[0, \rho H]$, $\bar{d} = r + \delta H$, $(\rho, \delta) = (0.25, 0.60), (0.50, 0.35)$ 이다.

seed는 서로소인 train/tuning/test 집합으로 분리한다. 주 해품질 비교(표 2)는 실험 조건당 test 인스턴스 20개 $\times$ replication 5회를 사용하고, 통제된 ablation은 동일예산·동일구조 분해이므로 원래의 5-인스턴스 설계를 유지한다. 인스턴스별로 replication을 평균한 뒤 짝지은 인스턴스 평균에 양측 Wilcoxon signed-rank test를 적용한다. GILS는 1,000회 반복한다. CP-SAT는 인스턴스당 1회, 8 thread로 S 300초 (5개), M/L 600초(조건당 2개) 실행하며 S-none 5개만 최적이 증명된다. 주 지표는 모든 방법과 예산 및 CP-SAT 결과를 포함하여 관측된 최선해에 대한 인스턴스별 gap Δ_{bo} 이다.

6. 실험 결과

6.1 해 품질

표 2이 20-인스턴스 test 결과를 요약한다. CP-SAT가 기준해를 제공한 실험 조건에서 GILS는 이에 근접하며, 기본 selector인 uniform 기준 0.11–0.21%이다 (학습 selector를 포함한 전체 변형은 0.1–0.6%). 같은 selector 기준으로 GILS는 VAA를 평균 2.65% ($n = 180, p < 10^{-4}$), SA-RL5를 1.38% ($n = 60, p < 10^{-4}$) 능가한다. 실행 시간은 S/M/L에서 각각 0.11, 0.52, 2.3초로, 같은 조건의 CP-SAT(76, 237, 376초)보다 두세 자릿수 짧다.

6.2 핵심 구성요소 분석: 성능은 어디에서 오는가

세 가지 통제된 ablation(예산 1,000회 고정)으로 엔진을 분해한다.

Operator pool. selection을 uniform으로 고정하고 연산자 집합만 generic(7)/critical(+g1,g2)/full(+g3,g4)로 바꾸면 Δ_{bo} 가 9개 실험 조건 전부에서 generic $\geq$ critical $\geq$ full로 단조 감소한다(그림 1). 짝지은 Wilcoxon(표 3)은 유도 연산자가 목적값을 일관되게·유의하게 낮춤을 보인다.

Table 3: Operator-pool ablation(실험 조건당 인스턴스 5개 $\times$ 반복 5회, 1,000회 예산 고정; 양측 Wilcoxon, + 평균 = 더 풍부한 연산자 집합이 우세).

대비	n	개선(%p)	p
generic $\rightarrow$ critical (g1,g2 추가)	136	+0.114	$< 10^{-4}$
critical $\rightarrow$ full (g3,g4 추가)	172	+0.048	$< 10^{-4}$
generic $\rightarrow$ full (전체 유도)	166	+0.161	$< 10^{-4}$




Figure 1: 연산자 집합별 관측된 최선해 대비 gap.

Engine components. 연산자 집합을 full, selection을 uniform으로 고정하고 구성요소를 하나씩 제거하면(표 4), best-improvement descent의 기여가 가장 크고 kick restart가 그다음이며, VAA 초기해는 통계적으로 유의하지 않고 확률적 acceptance는 제거해도 목적값이 나빠지지 않는다(그림 2).

Table 4: Engine-component ablation(실험 조건당 인스턴스 5개 × 반복 5회; leave-one-out 방식, 제거 시 상대 목적값 악화율).

제거 구성요소	n	악화(%p)	p
best-improvement descent	45	+0.156	$< 10^{-4}$
kick restart	43	+0.069	$< 10^{-4}$
VAA initial solution	45	+0.022	0.114
stochastic acceptance	45	-0.026	0.0014




Figure 2: 구성요소 제거 시 목적값 악화율.

6.3 보조 분석: 학습 기반 연산자 선택

연산자 집합과 구성요소를 full로 고정하고 selection만 바꾸면(표 5), 어떤 learned policy도 uniform을 실용적으로 능가하지 못한다. 50–3,000회의 모든 예산 구간에서도 결과는 같고 우열의 방향이 예산에 따라

뒤집히며(부록 그림 4), 이러한 부정적 결과는 무제약 조건만으로도 성립하므로 시간 제약 확장 때문에 나타난 결과가 아니다.

Table 5: selection 효과(실험 조건당 인스턴스 5개 $\times$ 반복 5회, 1,000회 예산; 양측 Wilcoxon, 양의 평균 = 앞 방법 우세).

비교	평균차(%p)	p	판정
tabular vs uniform	-0.01	0.150	차이 없음
tabular vs DQN	+0.10	$< 10^{-4}$	DQN 열세
uniform vs DQN	+0.11	$< 10^{-4}$	DQN 열세

6.4 Tardiness-weight 민감도

식 (16)이 시간 단위 성분 둘을 합치므로 tuning 집합에서 $\lambda \in \{0, 0.25, 0.5, 1, 2, 4, 8\}$ 을 스위칭한다. 물리적 makespan과 총 tardiness를 인스턴스별로 min-max 정규화해 평균한다(그림 3). tardiness 감소의 대부분은 $\lambda = 0$ 에서 1 사이에서 일어나고 이후에는 그 폭이 줄어든다. 전체 스위칭 구간에서 평균 makespan은 약 1% 상승, 평균 tardiness는 2-3% 하락한다. $\lambda = 1$ 을 채택한다: 완만한 makespan 비용으로 tardiness가 거의 최소에 이르고 두 시간 성분에 동일 가중을 준다. 이 스위칭은 test가 아닌 tuning 인스턴스를 사용한 설계 정당화이다.




Figure 3: tuning 인스턴스에서의 정규화된 makespan-tardiness trade-off.

7. 논의

학습 기반 selector가 uniform 대비 이득을 주지 못한 결과는 학습 자체에 대한 일반적 결론이 아니라, 본 논문의 탐색 구조 안에서 해석되어야 한다. 이 엔진은 selector가 개입할 여지를 거의 남기지 않기 때문이다. 후보 평가가 수십 μs 로 저렴하고, 모든 신규 incumbent 뒤에 결정론적 descent가 따른다. 같은 basin에 들어간 두 실행은 선행 이동이 달라도 같은 해로 수렴할 수 있으며, budget 곡선은 이 수렴이 대부분의 test 인스턴스에서 1,000회 이전에 일어남을 시사한다. 같은 이유로 SA acceptance와 reheating은 기저 SA-RL5 framework와의 comparability를 위해 유지하였으나, ablation은 본 설정에서 이들이 해 품질에 필수적이지 않음을 보인다.

학습 정책이 예측할 대상도 마땅치 않다. selector가 이득을 내려면 현재 탐색 상태에서부터 다음에 어떤 연산자가 유리한지를 예측할 수 있어야 하는데, 본 문제의 인스턴스는 정적이고 모든 release time이 최적화

이전에 알려져 있어 실행 도중 새로 드러나는 정보가 없다. 이는 도착 정보가 시간의 흐름에 따라 공개되는 online dock control이나 개별 이동의 평가 비용이 비싼 simulation 모형과 다르며, 그런 환경에서는 learned selection의 역할이 커질 수 있다. 본 결과가 뒷받침하는 바는 제한적이다. 즉, learned selector는 동일한 엔진과 동일한 예산에서 uniform sampling과 비교되어야 하며, 그 통제가 없으면 descent·restart·강한 이동 집합의 이득이 정책 자체의 것으로 잘못 귀속될 수 있다.

8. 결론

본 연구는 부분 하역 컴파운드 트럭 스케줄링에 release time과 soft due date를 도입하고, MILP·CP-SAT 정식화와 유효 하한으로 휴리스틱 해를 검증하였다. CP-SAT 기준해가 있는 실험 조건에서 VAA-GILS의 목적값은 해당 기준해 대비 평균 0.11–0.21%였고(소형 무제약 조건에서는 CP-SAT가 최적성을 증명하였다), 대형 시간 제약 조건에서는 수 초 안에 비교 방법 가운데 가장 좋은 해를 제공하였다. ablation은 성능이 best-improvement descent, guided 이동, restart라는 결정론적 구조에서 비롯되며, 학습 기반 연산자 선택·학습된 초기해·확률적 acceptance는 이 환경에서 실용적 이득을 주지 않음을 보였다. 향후에는 도착 정보가 실시간으로 공개되는 동적 문제, 대형 시간 제약 조건을 위한 더 강한 하한, 산업 데이터를 활용한 사례 연구가 필요하다.

A. Transfer DQN 구현 세부

transfer DQN은 매 반복 11개 연산자 집합에서 하나를 고른다. Q-network는 27차원 규모 불변 상태를 연산자별 Q값으로 사상하는 MLP로, 64 unit의 hidden layer 2개와 ReLU를 쓴다. 학습은 용량 100,000의 replay buffer를 사용하며, 500 transition warm-up 후 매 step 1회 gradient step으로 Huber(smooth- L_1) temporal-difference loss를 Adam (learning rate 10^{-3} , discount $\gamma = 0.9$)으로 최소화한다. mini-batch는 64, target network는 500 step마다 동기화한다. reward는 shaped signal(신규 incumbent 2, 비악화 1, 그 외 0)이다. agent는 *train* 집합(S/M 규모, 모든 화물 분포·시간 제약 조건)에서 500회 실행으로 오프라인 학습(ϵ -greedy) 후, *test* 인스턴스에 zero-shot ($\epsilon = 0$, 갱신 없음)으로 적용한다. 결과가 uniform 대비 개선이 없다는 것이므로, 재현·강화가 가능하도록 network·학습 스크립트·seed를 공개한다.




Figure 4: iteration budget 별 관측된 최선해 대비 gap. 50–3,000회에서 uniform은 0.47 → 0.16%, tabular는 0.56 → 0.09%, DQN은 0.56 → 0.26%로 움직이며, 어떤 예산에서도 learned selector가 uniform을 뚜렷하게 능가하지 않는다.

생성형 AI 사용 명시

원고 준비 과정에서 저자들은 언어 교정, 원고 구성, 참고문헌 확인, 계산 코드 개발·검토 보조를 위해 OpenAI Codex(GPT-5)와 Claude Code(Anthropic)를 사용하였다. 저자들은 모든 참고문헌·정식화·코드·결과·해석을 검토·검증하였으며 내용에 대한 전적인 책임을 진다.

References

- [1] M. T. Assadi and M. Bagheri, “Differential evolution and population-based simulated annealing for truck scheduling problem in multiple door cross-docking systems,” *Computers & Industrial Engineering*, vol. 96, pp. 149–161, 2016.
- [2] P. Bodnar, R. de Koster, and K. Azadeh, “Scheduling trucks in a cross-dock with mixed service mode dock doors,” *Transportation Science*, vol. 51, no. 1, pp. 112–131, 2017.
- [3] N. Boysen and M. Fliedner, “Cross dock scheduling: Classification, literature review and research agenda,” *Omega*, vol. 38, pp. 413–422, 2010.
- [4] C. M. Joo and B. S. Kim, “Scheduling compound trucks in multi-door cross-docking terminals,” *International Journal of Advanced Manufacturing Technology*, vol. 64, pp. 977–988, 2013.
- [5] D. Konur and M. M. Golias, “Analysis of different approaches to cross-dock truck scheduling with truck arrival time uncertainty,” *Computers & Industrial Engineering*, vol. 65, no. 4, pp. 663–672, 2013.
- [6] D. Konur and M. M. Golias, “Cost-stable truck scheduling at a cross-dock facility with unknown truck arrivals,” *Transportation Research Part E*, vol. 49, no. 1, pp. 71–91, 2013.
- [7] A.-L. Ladier and G. Alpan, “Robust cross-dock scheduling with time windows,” *Computers & Industrial Engineering*, vol. 99, pp. 16–28, 2016.
- [8] R. Larbi, G. Alpan, P. Baptiste, and B. Penz, “Scheduling cross docking operations under full, partial and no information on inbound arrivals,” *Computers & Operations Research*, vol. 38, no. 6, pp. 889–900, 2011.
- [9] Y. Li, M. Mohammadi, X. Zhang, Y. Lan, and W. van Jaarsveld, “Integrated trucks assignment and scheduling problem with mixed service mode docks: A Q-learning based adaptive large neighborhood search algorithm,” *European Journal of Operational Research*, vol. 333, no. 1, pp. 117–137, 2026.
- [10] D. Molavi, A. Shahmardan, and M. S. Sajadieh, “Truck scheduling in a cross docking systems with fixed due dates and shipment sorting,” *Computers & Industrial Engineering*, vol. 117, pp. 29–40, 2018.
- [11] A. Rijal, M. Bijvank, and R. de Koster, “Integrated scheduling and assignment of trucks at unit-load cross-dock terminals with mixed service mode dock doors,” *European Journal of Operational Research*, vol. 278, no. 3, pp. 752–771, 2019.
- [12] A. Shahmardan and M. S. Sajadieh, “Truck scheduling in a multi-door cross-docking center with partial unloading,” *Computers & Industrial Engineering*, vol. 139, Art. 106134, 2020.
- [13] J. Van Belle, P. Valckenaers, and D. Cattrysse, “Cross-docking: State of the art,” *Omega*, vol. 40, no. 6, pp. 827–846, 2012.
- [14] J. Van Belle, P. Valckenaers, G. Vanden Berghe, and D. Cattrysse, “A tabu search approach to the truck scheduling problem with multiple docks and time windows,” *Computers & Industrial Engineering*, vol. 66, no. 4, pp. 818–826, 2013.
- [15] C. J. C. H. Watkins and P. Dayan, “Q-learning,” *Machine Learning*, vol. 8, pp. 279–292, 1992.

- [16] V. Mnih et al., “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, pp. 529–533, 2015.
- [17] X. Xi, C. Liu, Y. Wang, and L. H. Lee, “Two-stage conflict robust optimization models for cross-dock truck scheduling problem under uncertainty,” *Transportation Research Part E*, vol. 144, Art. 102123, 2020.

Table 2: 20-인스턴스 test 결과(실험 조건당 인스턴스 20개 $\times$ 반복 5회). Δ_{bo} 는 관측된 최선해 대비 평균 gap, 시간은 1회 실행 평균이다. vs CP-SAT는 CP-SAT가 기준해를 제공한 부분집합(S 조건 각 5개, M-none 2개)에서만 계산하였으며, 이 가운데 S-none만 최적성이 증명되었다. 같은 부분집합에서 CP-SAT의 평균 실행시간은 S 조건 76초, M-none 237초이다.

실험 조건	방법	평균목적값 $\pm$ 표준편차	$\Delta_{bo}(\%)$	vs CP-SAT(%)	시간(초)
S-none	VAA	1497.5 $\pm$ 400.3	6.60	+6.49	0.00
	Paper-SA-RL5	1423.3 $\pm$ 383.6	1.03	+1.21	0.15
	GILS-uniform	1411.8 $\pm$ 382.7	0.16	+0.21	0.08
	GILS-tabular	1412.9 $\pm$ 381.3	0.28	+0.33	0.11
	GILS-DQN	1416.1 $\pm$ 382.4	0.51	+0.75	0.23
S-medium	VAA	5447.5 $\pm$ 1468.9	3.89	+3.33	0.00
	GILS-uniform	5255.7 $\pm$ 1413.3	0.08	+0.11	0.08
	GILS-tabular	5259.1 $\pm$ 1412.3	0.15	+0.18	0.11
	GILS-DQN	5270.8 $\pm$ 1415.3	0.38	+0.55	0.22
S-tight	VAA	9276.8 $\pm$ 2387.6	2.90	+2.17	0.00
	GILS-uniform	9010.8 $\pm$ 2206.1	0.09	+0.21	0.09
	GILS-tabular	9011.9 $\pm$ 2206.7	0.11	+0.17	0.11
	GILS-DQN	9022.0 $\pm$ 2205.3	0.23	+0.34	0.22
M-none	VAA	3030.9 $\pm$ 903.6	3.73	+4.80	0.00
	Paper-SA-RL5	2976.4 $\pm$ 864.4	1.86	+0.99	0.55
	GILS-uniform	2928.9 $\pm$ 842.6	0.29	+0.13	0.43
	GILS-tabular	2932.1 $\pm$ 846.3	0.37	+0.11	0.52
	GILS-DQN	2932.5 $\pm$ 845.5	0.40	+0.19	0.73
M-medium	VAA	23025.5 $\pm$ 4075.4	2.56	—	0.00
	GILS-uniform	22526.4 $\pm$ 3960.5	0.29	—	0.44
	GILS-tabular	22515.5 $\pm$ 3964.0	0.24	—	0.55
	GILS-DQN	22540.3 $\pm$ 3956.4	0.36	—	0.75
M-tight	VAA	38903.7 $\pm$ 11283.5	1.25	—	0.01
	GILS-uniform	38528.0 $\pm$ 11078.0	0.19	—	0.48
	GILS-tabular	38512.1 $\pm$ 11059.5	0.16	—	0.60
	GILS-DQN	38543.6 $\pm$ 11077.6	0.24	—	0.81
L-none	VAA	5492.3 $\pm$ 1482.2	2.21	—	0.02
	Paper-SA-RL5	5479.7 $\pm$ 1449.5	1.97	—	1.92
	GILS-uniform	5388.4 $\pm$ 1427.3	0.27	—	2.16
	GILS-tabular	5385.5 $\pm$ 1424.6	0.22	—	2.54
	GILS-DQN	5386.1 $\pm$ 1425.2	0.23	—	2.99
L-medium	VAA	55611.1 $\pm$ 18087.3	1.52	—	0.02
	GILS-uniform	54846.4 $\pm$ 17523.5	0.10	—	2.10
	GILS-tabular	54833.4 $\pm$ 17526.8	0.07	—	2.52
	GILS-DQN	54848.8 $\pm$ 17522.9	0.11	—	2.85
L-tight	VAA	119671.9 $\pm$ 32475.3	0.77	—	0.02
	GILS-uniform	118901.4 $\pm$ 31781.1	0.08	—	2.01
	GILS-tabular	118865.6 $\pm$ 31788.4	0.05	—	2.51
	GILS-DQN	118888.8 $\pm$ 31789.1	0.07	—	2.76