

도착 시각(release time)과 연성 납기(soft due date)를 갖는 입출고 병행 트럭 크로스도킹 스케줄링: CP-SAT 기준해 비교를 동반한 병목 유도 반복 지역탐색

Compound-Truck Cross-Docking Scheduling with Release Times and Soft Due Dates: A
Bottleneck-Guided Iterated Local Search with CP-SAT Benchmarking

Abstract

We study truck scheduling in a multi-door cross-dock where a compound truck is partially unloaded and then departs as the outbound carrier of its retained destination. Release times and due dates are well studied for conventional inbound and outbound trucks, but existing compound-truck models assume that all trucks are available at time zero and minimize makespan only. We formulate, as a mixed-integer program and a CP-SAT model, how per-truck release times and soft due dates interact with this carrier conversion and its transfer precedence: a late arrival delays every carrier that waits for its freight, and soft due dates turn the propagated delay into tardiness cost. To our knowledge, this delay-propagation structure has not been modeled before; the objective is makespan plus total tardiness. VAA-GILS is an iterated local search combining Vogel-style construction, best-improvement descent, bottleneck-guided operators, kick restarts, and greedy acceptance. Where CP-SAT provides a reference solution, VAA-GILS is within 0.06–0.25% of that reference while requiring substantially less computation time (under 0.5 versus 40–606 seconds); on the 20 S-none instances, for all of which CP-SAT proved optimality, VAA-GILS is on average 0.25% above the optimum. Where CP-SAT finds no feasible schedule within 600 seconds, VAA-GILS returns the best solutions observed among the compared methods. Ablation attributes the gain to this deterministic structure, not to learned operator selection or stochastic acceptance.

Keywords: Cross-Docking, Compound Truck, Release Time, Soft Due Date, Iterated Local Search, Constraint Programming

1. 서론

크로스도킹은 입고 화물을 창고에 보관하지 않고 곧바로 출고트럭으로 환적하여 재고와 리드타임을 줄이는 물류 방식이다(Boysen and Fliedner, 2010; Van Belle et al., 2012). Joo와 Kim(2013)이 도입하고 Shahmardan과 Sajadieh(2020)가 발전시킨 병행 트럭(compound truck) 변형에서는 한 대의 트럭이 두 역할을 겸한다. 여러 목적지 화물을 싣고 도착한 뒤 한 목적지의 화물은 유지하고 나머지만 부분적으로 하역

하며, 이후 해당 목적지의 나머지 화물을 적재해 출고 운송 트럭으로 출발한다. 부분 하역은 전량 하역 대비 총 작업완료시간(makespan)을 크게 줄이는 것으로 보고되어 LTL(Less-Than-Truckload, 소량 화물 혼적) 통합 네트워크에서 실용적 매력이크다.

기존 병행 트럭 모델의 두 가정이 현실성을 제약한다. 첫째, 모든 트럭이 시각 0에 가용하다고 가정하지만 실제 도크에서는 트럭마다 예약 도착 시각(release time)이 다르다. 둘째, 목적식이 순수 총 작업완료시간이지만 출고트럭의 출발은 위반 시 비용이 발생하는 납기(due date)에 묶여 있다.

도착 시각, 시간창(time window), 납기지연(tardiness)은 일반 크로스도킹 스케줄링에서 이미 연구되어 왔다(Van Belle et al., 2013; Assadi and Bagheri, 2016; Bodnar et al., 2017; Molavi et al., 2018; Rijal et al., 2019; Li et al., 2026). 그러나 병행 트럭 설정은 temporal constraint의 의미를 바꾼다. 병행 트럭은 순수 입고트럭도 출고트럭도 아니다. 부분 하역 후 한 목적지의 화물을 유지하고, 해당 목적지로 들어오는 이송 화물을 기다린 뒤 비로소 출고 운송 트럭으로 출발한다. 이 부분 하역 변환은 하나의 precedence chain — 도착 → 부분 하역 → 유지 화물 → 이송 대기 → 출고 — 을 만들고, 이 chain은 트럭들을 공유 목적지를 통해 결합한다. 따라서 도착 시각을 추가한다고 해서 한 트럭의 시작 시각만 늦어지는 것은 아니다. 늦은 도착은 해당 트럭의 이송 화물에 의존하는 모든 출고 운송 트럭으로 전파되고, 연성 납기(soft due date)는 이 연쇄 지연을 납기지연 비용으로 바꾼다. 본 연구의 기여는 이 상호작용 — 알려진 도착 시각과 연성 납기가 부분 하역 후 출고 운송 트럭으로 전환되는 과정과 결합되는 방식 — 을 정식화하고 분석하는 것이며, 저자가 아는 한 이 결합은 이전에 모형화된 바 없다.

본 논문의 기여와 기존 연구 대비 차별성은 다음 세 가지이며, 대표 연구와의 비교는 <Table 1>에 정리하였다. 첫째, 문제 정식화의 차별성이다. 도착 시각이나 납기를 다룬 기존 연구(Van Belle 등, 2013; Assadi and Bagheri, 2016; Bodnar 등, 2017; Rijal 등, 2019; Theophilus 등, 2021; Li 등, 2026)는 모두 입고·출고 역할이 고정된 트럭을 전제하고, 병행 트럭을 다룬 연구(Shahmardan and Sajadieh, 2020; Nowak and Puladi, 2025)는 모든 트럭이 시각 0에 가용하다고 보고 총 작업완료시간만 최소화한다. 본 연구는 부분 하역 병행 트럭이 운송 트럭으로 전환되는 선행 관계에 트럭별 도착 시각과 연성 납기를 결합한 모형을 저자가 아는 한 처음 제시하고, 이를 독립적인 스케줄 평가기와 일치하는 big- M MILP 및 reified CP-SAT로 정식화한다. 이 결합에서는 한 트럭의 늦은 도착이 공유 목적지를 통해 다른 운송 트럭의 납기지연으로 전파되므로, 두 계열 가운데 어느 한쪽 모형의 단순한 확장으로는 나타나지 않는 지연 구조가 생긴다. 둘째, 해법의 차별성이다. Shahmardan과 Sajadieh(2020)의 SA-RL5는 한 반복에 이동 하나를 simulated annealing으로 수락하는 순수 SA이고, 최근의 학습형 메타휴리스틱(Karimi-Mamaghan 등, 2023; Li 등, 2026)은 연산자 선택 자체를 학습한다. 본 연구는 원 모델의 VAA 구성 휴리스틱과 기본 이웃 구조에,

병목 트럭과 납기지연이 큰 트럭을 직접 겨냥하는 병목 유도 연산자(bottleneck-guided operator), 개선 시 적용하는 최선개선 하강 탐색(best-improvement descent), 섭동 재시작(kick restart)을 결합한 VAA-GILS를 제안하며, 이 해법은 같은 반복 횟수뿐 아니라 같은 실행 시간에서도 원 모델 계열의 해법보다 좋은 해를 찾는다. 셋째, 검증 방식의 차별성이다. 소형 무제약 조건의 20개 인스턴스 전부에서 CP-SAT로 최적성을 증명하여 휴리스틱의 최적해 대비 격차를 제시하고, 최적해·기준해·관측 최선해를 구분하여 보고한다. 또한 학습 기반 연산자 선택을 동일한 엔진과 동일한 반복 횟수의 균등 선택과 비교하는 통제된 ablation으로, 학습형 선택이 해를 개선한다는 보고와 달리 강한 지역탐색을 갖춘 본 해법에서는 그 이득이 나타나지 않음을 보조적으로 확인한다.

본 논문의 구성은 다음과 같다. 제 2장에서 관련 연구를 정리하고, 제 3장에서 문제를 정의하며 혼합정수 계획 모형과 CP-SAT 모형을 제시한다. 제 4장에서 제안 알고리즘인 VAA-GILS를 서술하고, 제 5장과 제 6장에서 실험 설계와 결과를 제시한다. 제 7장에서 결과를 논의하고 제 8장에서 결론을 맺는다.

2. 관련 연구

시간 제약이 있는 크로스도킹 스케줄링. Boysen과 Flidner(2010)는 도크 스케줄링 문제를 분류하였고, Van Belle 등(2012)은 분야를 조망하였다. 여러 결정론적 모형이 기존 입고·출고트럭에 대해 시간 제약을 이미 반영한다. Van Belle 등(2013)은 다중 도어·time window·납기지연을, Assadi와 Bagheri(2016)는 ready time과 outbound 조기완료와 납기지연(earliness/tardiness)을, Bodnar 등(2017)은 time window와 mixed-service door를 다룬다. Molavi 등(2018)은 경성 납기(hard due date)를, Rijal 등(2019)은 truck scheduling과 door assignment의 통합을 다룬다. 이들은 도착 시각과 납기 자체가 새롭지 않음을 보이나, 입고·출고트럭을 구분하며 부분 하역 후 출고 운송 트럭으로 전환되는 트럭을 모형화하지 않는다. 최근의 Theophilus 등(2021)도 cold-chain 터미널에서 부패성 제품의 품질 저하, 트럭 도착 시각, 예정 출발 시각을 넘긴 지연 출발 비용을 함께 고려하지만 입고트럭과 출고트럭은 서로 구분된다. 병행 트럭 계열의 후속 연구는 드물다. Nowak과 Puladi(2025)는 혼합 서비스 도어와 작업 선점을 허용하면서 하역을 마친 트럭이 다시 적재되는 병행 트럭을 다루고 메타휴리스틱으로 총 작업완료시간을 최소화하지만, 트럭은 신고 온 화물을 모두 하역한 뒤 적재되고 도착 시각이나 납기는 두지 않는다. 출고트럭의 반복 적재를 허용한 Pan 등(2021)은 병행 트럭을 다루지 않으며 모든 트럭이 시각 0에 가용하다고 가정한다. Shahmardan과 Sajadieh(2020)를 인용한 문헌 가운데에서도 부분 하역 병행 트럭에 도착 시각과 납기를 결합한 연구는 확인되지 않았다.

불확실·불완전 도착 정보. 도착 정보의 불확실성은 앞서 다룬 결정론적 시간 제약 연구들과는 별개의 흐름을 이룬다. Konur와 Golias는 bounded arrival window(2013a)와 unknown arrival 하의 cost-stable

schedule(2013b)을 다룬다. Larbi 등(2011)은 도착 정보의 완전·부분·부재(full/partial/absent) 정보를 구분하고, Ladier와 Alpan(2016)은 time window 하의 robust schedule을, Xi 등(2020)은 two-stage conflict robust optimization을 제시한다. 본 모형은 결정론적이며 각 도착 시각은 스케줄 구성 시점에 알려져 있다. 따라서 이들 불확실성 모형은 본 모형을 직접 대체하기보다 향후 자연스럽게 확장할 수 있는 연구 방향에 해당한다.

가장 유사한 문제와 학습형 메타휴리스틱. Li 등(2026)은 무인 배송센터(distribution center)를 대상으로 mixed service mode dock의 통합 트럭 배정·스케줄링을 Q-learning 기반 ALNS(adaptive large neighborhood search; Ropke and Pisinger, 2006)로 푼다. 이들 역시 도착 시각과 연장 가능한 출발 예정 시각을 시간 창 (r_i, d_i) 로 두고 납기지연과 총 작업완료시간을 목적에 포함하므로, 시간 제약의 형태 자체는 본 연구와 유사하다. 그러나 유연성이 도어 수준에 있어 도어가 적재 전용·하역 전용·혼합 모드 중 하나를 선택하고 트럭은 순수 입고·출고트럭으로 고정되며, 화물은 도어 간 직접 이송이 아니라 저장 구역을 경유해 AGV가 운반한다. 반면 본 문제의 유연성은 트럭 수준에 있어, 부분 하역된 병행 트럭이 특정 목적지의 운송 트럭으로 전환되고 화물은 도어 간에 직접 이송된다. 한편 이들과 함께 cross-dock door assignment에 강화 학습 기반 strategic oscillation을 적용한 Li 등(2024), iterated greedy에 Q-learning 연산자 선택을 통합한 Karimi-Mamaghan 등(2023)처럼 학습 기반 탐색 제어가 메타휴리스틱을 개선한다는 보고가 많으나, 본 연구는 강한 지역 탐색을 갖춘 뒤에는 학습 기반 선택 정책의 이득이 작다는 통제된 반례를 더한다. 대표 연구와 본 연구의 문제·해법 차이는 <Table 1>에 요약하였다.

3. 문제 정의

3.1 기본 모델

I, F, D, K, M 을 각각 병행 트럭, 출고트럭, 목적지, 상품 종류, 도어의 집합이라 하고 $|I| + |F| = |D|$, $|I| \leq |M|$ 이라 하자. 병행 트럭 i 는 목적지 d 행 상품 k 를 화물량 f_{idk} 만큼 싣는다. 단위 처리시간 t_k , 도어 m, n 간 배치 이송시간 t_{mn} , 트럭 i 의 진입·출차 전환시간 DE_i, DL_i 에 대해 $h_{id} = \sum_k f_{idk}t_k$, $H_i = \sum_d h_{id}$ 로 둔다. 각 병행 트럭은 유지할 목적지 하나와 도어 하나를(도어당 병행 트럭 최대 1대), 각 출고트럭은 남은 목적지 하나와 도어를 고르며, 같은 도어의 출고트럭은 작업 순서를 정한다. 각 목적지에는 정확히 하나의 운송 트럭이 배정된다.

각 트럭 $q \in I \cup F$ 의 도착 시각을 r_q 로 나타낸다. 따라서 r_i 는 병행 트럭 $i \in I$ 가 도어 작업을 시작할 수 있는 가장 이른 시각이고, r_f 는 출고트럭 $f \in F$ 가 도어 작업을 시작할 수 있는 가장 이른 시각이다. 위반이 허용되는 연성 납기 $\bar{d}_q$ 와 그에 따른 납기지연 T_q 는 3.3절에서 정의한다.

Table 1. Positioning of this study against representative cross-docking truck scheduling studies. Temporal constraints are truck arrival, release, due-date, or departure-time restrictions; “—” in the partial-unloading column denotes models without compound trucks.

Study	Truck roles	Partial unloading	Temporal constraints	Objective	Solution method
Van Belle et al. (2013)	Inbound/outbound	—	Time windows	Travel time + tardiness	Tabu search
Assadi and Bagheri (2016)	Inbound/outbound	—	Ready times	Earliness + tardiness	MILP, DE, PBSA
Bodnar et al. (2017)	Inbound/outbound; mixed-service doors	—	Time windows	Cost including tardiness	ALNS
Rijal et al. (2019)	Inbound/outbound; mixed-service doors	—	Arrival and departure times	Tardiness + storage + travel cost	ALNS
Shahmardan and Sajadieh (2020)	Compound + outbound; mixed-service doors	Yes	None (all at time 0)	Makespan	Heuristic, RL-based SA
Theophilus et al. (2021)	Inbound/outbound	—	Arrival times, scheduled departures	Total cost incl. delayed departure and decay	Evolutionary algorithm
Nowak and Puladi (2025)	Compound; mixed-service doors, preemption	No (full unloading)	None (all start at time 0)	Makespan	GA, VNS
Li et al. (2026)	Inbound/outbound; mixed-mode docks	—	Time windows	Tardiness, makespan, AGV travel	Q-learning ALNS
This study	Compound + outbound	Yes	Release times + soft due dates	Makespan + λ -tardiness	MILP, CP-SAT, VAA-GILS

시간 계산은 스케줄 평가기 규칙을 따른다. 병행 트럭 i (목적지 d 유지)의 하역은 $r_i + DE_i + \sum_{d' \neq d} h_{id'}$ 에 끝난다. 운송 트럭은 화물을 보내는 모든 트럭의 하역과 도어 간 이송이 끝나야 적재할 수 있다. 출고 운송 트럭 f 는 추가로 자신의 도착 시각과 도어의 선행 점유가 끝나는 시점에 도어 작업을 시작하여 $S_f = \max(\text{door available, destination ready, } r_f)$ 이며, 이후 진입(DE_f), 적재, 출차(DL_f)를 차례로 수행하므로 완료 시각은 $S_f + DE_f + L_d + DL_f$ 이다. 즉 S_f 는 적재 시작이 아니라 도어 작업 시작 시각이고, 적재는 $S_f + DE_f$ 에 시작한다. 총 작업완료시간 $\tau = C_{\max}$ 는 최대 완료 시각이다.

3.2 Mixed-integer 정식화

이진 변수 x_{idm} 은 병행 트럭 $i \in I$ 를 유지 목적지 d ·도어 m 에, z_{fdm} 은 출고트럭 $f \in F$ 를 배정한다. $X_{im} = \sum_d x_{idm}$, $Z_{fm} = \sum_d z_{fdm}$, $Z_{fd} = \sum_m z_{fdm}$ 로 두고, b_{fgm} 은 도어 m 에서 f 가 g 에 선행하면 1이다. 연속 변수 $U_i, C_i, S_f, C_f, C_{\max}$ 는 각각 병행 트럭의 하역 완료, 병행 트럭의 도어 작업 완료, 출고 도어 작업 시작, 출고 완료, 총 작업완료시간이다. $L_{id} = \sum_{j \neq i} h_{jd}$, $L_d = \sum_i h_{id}$, B 는 유효한 horizon 상한이다.

배정 제약은 다음과 같다.

$$\sum_{d,m} x_{idm} = 1 \quad \forall i \quad (1)$$

$$\sum_{d,m} z_{fdm} = 1 \quad \forall f \quad (2)$$




Figure 1. Processing timelines for the two alternative carrier configurations: (a) a compound truck retaining destination d , and (b) a dedicated outbound truck assigned to destination d .

$$\sum_{i,m} x_{idm} + \sum_{f,m} z_{fdm} = 1 \quad \forall d \quad (3)$$

$$\sum_{i,d} x_{idm} \leq 1 \quad \forall m \quad (4)$$

병행 트럭의 시간 관계와 유입 이송 선행 제약은 다음과 같다.

$$U_i = r_i + DE_i + H_i - \sum_{d,m} h_{id} x_{idm} \quad \forall i \quad (5)$$

$$C_i \geq U_i + L_{id} + DL_i - B(1 - x_{idm}) \quad \forall i, d, m \quad (6)$$

$$C_i \geq U_j + t_{nm} + L_{id} + DL_i - B(2 - x_{idm} - X_{jn}) \quad (7)$$

식 (7)은 모든 i, d, m, n 과 $\sum_k f_{jdk} > 0$ 인 기여 트럭 $j \neq i$ 에 대해 성립한다.

출고 운송 트럭에 대해서는 다음이 성립한다.

$$S_f \geq r_f \quad \forall f \quad (8)$$

$$C_f \geq S_f + DE_f + L_d + DL_f - B(1 - Z_{fd}) \quad \forall f, d \quad (9)$$

$$S_f \geq U_i + t_{nm} - B(2 - z_{fdm} - X_{in}) \quad (10)$$

식 (10)은 모든 f, d, m, n 과 $\sum_k f_{idk} > 0$ 인 기여 병행 트럭 i 에 대해 성립한다.

$$S_f \geq C_i - B(2 - Z_{fm} - X_{im}) \quad \forall f, i, m \quad (11)$$

같은 도어 m 을 쓰는 출고트럭 쌍 $f < g$ 에 대한 순서 결정과 non-overlap 제약은 다음과 같다.

$$b_{fgm} + b_{gfm} \geq Z_{fm} + Z_{gm} - 1, \quad b_{fgm} \leq Z_{fm}, \quad b_{gfm} \leq Z_{gm} \quad (12)$$

$$S_g \geq C_f - B(1 - b_{fgm}) \quad (13)$$

$$S_f \geq C_g - B(1 - b_{gfm}) \quad (14)$$

끝으로 총 작업완료시간은 다음으로 정의된다.

$$C_{\max} \geq C_i \quad \forall i, \quad C_{\max} \geq C_f \quad \forall f \quad (15)$$

CP-SAT 모형은 big- M disjunction을 enforcement literal로 대체하고 모든 시간값을 가장 가까운 0.01 단위로 반올림한 뒤 100배하여 정수로 변환하며, 모든 배정을 고정하면 독립 평가기의 완료 시각이 재현되어 model fidelity가 확인된다.

3.3 시간 제약 확장과 목적식

각 트럭 $q \in I \cup F$ 는 앞서 정의한 도착 시각 $r_q \geq 0$ 과 연성 납기 $\bar{d}_q$ 를 갖고 $T_q \geq \max\{0, C_q - \bar{d}_q\}$ 이다.

목적식은

$$\min J = C_{\max} + \lambda \sum_{q \in I \cup F} T_q, \quad \lambda = 1 \quad (16)$$

λ 는 납기지연 한 단위 시간에 부과하는 벌점 계수(penalty coefficient)로, 총 작업완료시간과 납기 준수 사이의 관리적 선호를 반영하는 파라미터이다(6.4절). $r_q = 0, \bar{d}_q = \infty$ 이면 기존 총 작업완료시간 모델로 환원된다. CP-SAT는 현재 최선해(현재 최선해)와 증명된 하한을 함께 반환하며, 하한과 일치가 증명될 때에만 최적으로 부른다.

3.4 조합적 하한

CP-SAT가 제공하는 하한이 약한 실험 조건에서 격차를 보고하기 위해 도어 경합을 완화한 두 유효 하한을 사용한다. 병행 트럭 i (목적지 d 유지)의 최속 완료와 출고트럭 f 의 최속 완료는

$$EF_i = r_i + DE_i + \min_{d \in D} \left(H_i - h_{id} + \sum_{j \in I \setminus \{i\}} h_{jd} \right) + DL_i \quad (17)$$

$$EF_f = r_f + DE_f + \min_{d \in D} \sum_{j \in I} h_{jd} + DL_f \quad (18)$$

critical-chain 하한은 $LB_{cc} = \max_{q \in I \cup F} EF_q$ 이다. door-area 하한은 각 트럭의 최소 도어 점유

$$o_i = DE_i + \left(H_i - \max_d h_{id} \right) + \min_d \sum_{j \in I \setminus \{i\}} h_{jd} + DL_i \quad (19)$$

$$o_f = DE_f + \min_d \sum_{j \in I} h_{jd} + DL_f \quad (20)$$

을 도어 수로 나눈 값이다.

$$LB_{da} = \frac{1}{|M|} \left(\sum_i o_i + \sum_f o_f \right) \quad (21)$$

총 작업완료시간 하한과 구조적 지연 하한을 각각 $LB_\tau = \max\{LB_{cc}, LB_{da}\}$ 와

$$LB_T = \sum_{q: \bar{d}_q < \infty} \max\{0, EF_q - \bar{d}_q\} \quad (22)$$

로 두고 $LB_J = LB_\tau + \lambda LB_T$ 라 하자.

명제 1. 식 (1)–(16)의 모든 실행 가능해에 대해 $C_{\max} \geq LB_\tau$, $\sum_{q \in I \cup F} T_q \geq LB_T$ 이며, 따라서 $\lambda \geq 0$ 이면 $J \geq LB_J$ 이다.

증명. (i) 최속 완료. 도어 경합을 나타내는 식 (4), (11)–(14)와 도어 간 이송시간 $t_{nm} \geq 0$ 을 제거하면 각 트럭의 완료 시각은 작아질 수만 있다. 병행 트럭 i 가 목적지 d 를 유지하면 식 (5), (6)에서 $C_i \geq r_i + DE_i + (H_i - h_{id}) + L_{id} + DL_i$ 이고, d 에 대해 최솟값을 취하면 $C_i \geq EF_i$ 이다. 출고트럭 f 가 목적지 d 를 맡으면 식 (8), (9)에서 $C_f \geq r_f + DE_f + L_d + DL_f$ 이고, $L_d = \sum_{j \in I} h_{jd}$ 이므로 $C_f \geq EF_f$ 이다. 식 (15)에 의해 $C_{\max} \geq \max_q EF_q = LB_{cc}$ 이다. (ii) 도어 점유. 병행 트럭 i 는 구간 $[r_i, C_i]$ 동안, 출고트럭 f 는 $[S_f, C_f]$ 동안 한 도어를 점유하며, (i)과 같은 부등식에서 두 구간의 길이는 각각 o_i 와 o_f 이상이다(목적지 선택과 무관하게 하역량과 적재량을 각각 따로 최소화하였다). 식 (4), (11), (13), (14)에 의해 같은 도어의

점유 구간은 겹치지 않고 모든 구간은 $[0, C_{\max}]$ 에 포함되므로 $\sum_i o_i + \sum_f o_f \leq |M| C_{\max}$, 곧 $C_{\max} \geq LB_{da}$ 이다. (iii) 지연. $T_q \geq 0$ 과 $T_q \geq C_q - \bar{d}_q \geq EF_q - \bar{d}_q$ 에서 $T_q \geq \max\{0, EF_q - \bar{d}_q\}$ 이고, $\bar{d}_q = \infty$ 인 트럭은 0을 더하므로 $\sum_q T_q \geq LB_T$ 이다. (iv) (i)–(iii)과 $\lambda \geq 0$ 에서 $J = C_{\max} + \lambda \sum_q T_q \geq LB_T + \lambda LB_T = LB_J$ 이다. $\square$

두 항을 서로 독립적으로 완화하므로 LB_J 는 느슨할 수 있으며, 특히 도어 경합이 큰 대형 시간 제약 조건에서 그 차이가 커진다.

4. 휴리스틱 알고리즘

VAA-GILS는 iterated local search(Lourenço 등, 2019)의 구현체로, 연산자 선택, 연산자 내부 sampling, kick을 제외하면 결정론적이다. 이하에서 원 모델은 Shahmardan과 Sajadieh(2020)가 제안한 SA-RL5를 가리키며, VAA 구성 휴리스틱과 기본 이웃 7종은 이 모델에서 가져왔다.

초기해 구성. 원 모델의 VAA는 Vogel식 regret으로 병행 트럭의 유지 목적지를 정하고, 완료 시각 우선 순위에 따라 출고 목적지를 배정한다. 도어 배정은 먼저 처리되는 트럭을 도어 간 이송시간 합이 가장 작은 중앙 도어에 두고, 나머지 트럭은 작업 종료가 가장 이른 도어에 차례로 삽입한다. 모든 완료 예정 시각 계산에는 도착 시각을 반영한다.

하강 탐색. 세 가지 이동 유형(출고트럭 재배치, 병행 트럭의 도어 교환/빈 도어 이동, 두 트럭의 목적지 교환)에 대한 최선개선 지역탐색으로, 지역 최적해(Local Optimum)에서 종료하며 초기해·새로 갱신된 현재 최선해·최종해에 적용한다.

반복 탐색. 1,000회 반복한다. 선택 정책이 연산자 하나를 뽑아 현재 해에서 후보를 생성하고, 후보가 전역 최선해를 개선하면 하강 탐색을 적용해 현재 최선해를 갱신한다. 수락 규칙(acceptance)은 후보가 현재 해를 엄격히 개선할 때만 받아들이는 greedy 규칙이다. 이 규칙은 조정 집합에서 simulated annealing(Kirkpatrick 등, 1983) 수락 규칙(초기 온도 $T_0 = \max\{1, 0.05 J(s_0)\}$, 기하 냉각 $T \leftarrow 0.995 T$, 재시작 시 reheating)와 비교해 정하였다. 조정 집합 45개 인스턴스 중 33개에서 SA 수락 규칙의 목적값이 greedy보다 높았고 (인스턴스별 차이의 중앙값 +0.017%p, 양측 Wilcoxon $p = 0.023$), 평균 차이는 한 인스턴스의 큰 차이 때문에 -0.011%p였다. 시간 제약이 없는 조건(+0.084%p, $p = 0.083$)과 있는 조건(-0.058%p, $p = 0.051$)으로 나누어도 SA의 유의한 우위는 없었다.

섭동 재시작. 30회 연속 개선이 없으면 섭동 재시작을 수행한다. 현재 최선해 s^* 의 복사본에서 다시 시작하되, 아래 기본 이웃 7종에서 균등 무작위로 뽑은 이동(kick)을 3회 연속 적용한다. 각 이동은 직전 이동의 결과에 적용되며, 재시작 직후에는 하강 탐색을 수행하지 않는다.

연산자 집합(operator pool). 기본 이웃 7종은 원 모델의 이웃 구조를 그대로 사용한다: (k1) 두 트럭의 목적지 교환, (k2) 병행 트럭 간 도어 교환, (k3) 출고트럭 간 도어 교환, (k4) 출고트럭을 다른 도어로 삽입, (k6) 하역시간 기반 룰렛 선택으로 병행 트럭을 도어에 삽입, (k7) 적재시간 기반 룰렛 선택으로 출고트럭을 도어에 삽입, (k8) 룰렛 선택으로 병행 트럭에 목적지를 배정. 원 모델은 이동을 k1–k8로 번호매기나 k5는 정의하지 않아 실제 구현은 7종이다. 여기에 현재 병목을 먼저 식별한 뒤 그 주변에서 가능한 후보를 모두 평가해 최선을 택하는 유도 연산자 4종을 더한다: (g1) 병목 도어(critical door)의 마지막 출고트럭을 최선 도어·위치로 재배치, (g2) 병목 트럭의 목적지를 전 트럭과 대조해 최선 교환, (g3)/(g4) 납기지연이 가장 큰 트럭 기준의 동일 이동(납기지연이 있는 트럭이 없으면 g1/g2로 대체). 고속 증분 평가기는 해 하나를 평가하는 데 시험 인스턴스 기준 S에서 약 25–28마이크로초(μs), L에서 약 95–148마이크로초가 걸려 하강 탐색과 유도 연산자를 저렴하게 만든다.

선택 정책과 원 모델의 비교. 선택 정책은 교체할 수 있으며 기본값은 균등 무작위 선택이다. 학습 정책(SA-RL5의 tabular Q-learning(Watkins and Dayan, 1992), 규모 불변 특징(feature)으로 오프라인 학습한 transfer DQN(Mnih 등, 2015))은 ablation 목적으로만 평가하며 제안 방법의 일부가 아니다. tabular Q는 원 모델과 같이 무개선 구간 5-상태에서 ε -greedy 탐험과 룰렛 활용을 쓰되, 보상은 원 모델의 이진 보상(후보가 현재 해보다 나쁘지 않으면 1, 아니면 0) 대신 현재 최선해 갱신 2·비약화 1·그 외 0의 셰이핑 보상을 사용한다. 이는 학습 신호를 강화할 뿐이므로 비교 대상 선택 정책을 불리하게 만들지 않는다. 원 모델 SA-RL5는 RL이 단일 이동을 고르고 SA 수락·거절로 한 단계가 끝나는 순수 simulated annealing인 반면, VAA-GILS는 그 한 연산자 적용 단계를 iterated local search 안에 넣고 유도 연산자, 개선 이동마다의 하강 탐색, 섭동 재시작을 더하며, 확률적 수락 규칙 대신 greedy 수락 규칙을 쓴다. ablation(6.2절)은 이 가운데 섭동 재시작의 기여가 가장 크고 유도 연산자와 하강 탐색이 그 뒤를 이음을 보인다. 두 방법의 구조적 차이는 <Table 2>에 정리하였다.

Table 2. Structural comparison of the base SA-RL5 and VAA-GILS.

Aspect	SA-RL5 (base)	VAA-GILS (proposed)
Overall framework	Pure simulated annealing	Iterated local search
Operators per iteration	One	One (same)
Operator set	7 generic neighborhoods	Those 7 + 4 guided
Operator selection	Online Q-learning / roulette	Uniform random (learning only in ablation)
After an improving move	None (the SA step is the whole iteration)	Full best-improvement descent
Stagnation handling	None	Kick restart
Acceptance	SA (Metropolis)	Greedy (improving candidates only)
Objective	Makespan	Makespan + $\lambda \cdot$ total tardiness

5. 실험 설계

5.1 인스턴스 생성

병행 트럭 $|I|$, 출고트럭 $|F|$, 목적지 $|D| = |I| + |F|$, 도어 $|M| = |I|$ 로 두고 세 규모를 사용한다: S ($|I|, |F|$) = (6, 3), M (12, 6), L (20, 10). 따라서 $(|I|, |D|, |M|)$ 는 각각 (6, 9, 6), (12, 18, 12), (20, 30, 20) 이고 병행 트럭 비율 $|I|/|D|$ 는 모두 $2/3$ 이다. S는 CP-SAT가 일부 조건에서 제한시간 안에 최적성을 증명할 수 있는 소규모 문제이며, L은 제한시간 안에 실행 가능해 확보도 어려운 대규모 문제여서 두 극단을 함께 본다. 병행 트럭 비율을 높게 잡은 것은, 이 비율이 낮으면 문제가 일반 크로스도킹 스케줄링에 가까워져 부분 하역 구조의 영향이 드러나지 않기 때문이다.

나머지 생성 파라미터는 <Table 3>에 정리하였다. 화물이 특정 목적지로 쏠리는 정도는 이와 별개의 조건이며, 보고하는 모든 실험은 쏠림이 없는 조건을 사용한다(쏠린 조건과 군집 조건은 부록 A의 transfer DQN 학습에만 쓴다). 도어를 일렬로 늘어놓으면 이송시간이 도어 번호 차이로 정해져 도어 배정이 해에 미치는 영향이 작아지므로, 배정 결정이 실제로 품질을 가르도록 무작위 배치를 쓴다. 이송 거리를 10으로 나누는 것은 이송시간을 처리시간과 같은 크기 범위에 두기 위해서다.

Table 3. Instance generation parameters. Flow, handling and enter/leave times are drawn from integer uniform distributions.

Item	Symbol	Value
Size (compound/outbound/destination/door)	(I , F , D , M)	S (6, 3, 9, 6); M (12, 6, 18, 12); L (20, 10, 30, 20)
Compound-truck ratio	$ I / D $	$2/3$
Number of product types	$ K $	3
Flow	f_{idk}	$U[0, 20]$
Unit handling time	t_k	$U[1, 4]$
Enter/leave time	DE_q, DL_q	$U[1, 5]$
Door coordinates	—	uniform on $[0, 100]^2$
Inter-door travel time	t_{mn}	Euclidean distance / 10
Release time	r_q	none: 0; otherwise $U[0, \rho H]$
Soft due date	$\bar{d}_q$	none: ∞ ; otherwise $r_q + \delta H$
Time-constraint level	(ρ, δ)	medium (0.25, 0.60); tight (0.50, 0.35)

5.2 시간 제약 수준

시간 제약은 none, medium, tight 세 수준이다. none은 $r_q = 0, \bar{d}_q = \infty$ 로 두어 모든 트럭이 시각 0에 가용하고 납기가 없는 기존 모델과 같으며, 본 연구의 확장을 썼을 때의 대조군 역할을 한다. medium과 tight에서는 $r_q \sim U[0, \rho H], \bar{d}_q = r_q + \delta H, (\rho, \delta) = (0.25, 0.60), (0.50, 0.35)$ 이다. 여기서 $H = 2 \sum_{i \in I} H_i / |M|$ 는 시간 제약이 없을 때의 총 작업완료시간 추정치로, 화물 한 단위가 하역과 적재로 두 번 처리되므로 계수 2를 둔다. 시간 제약을 H 의 비율로 주면 규모가 달라져도 압박 수준이 유지된다. ρ 는 도착이 퍼지는 폭, δ 는

도착 후 납기까지의 여유를 뜻하므로, tight는 두 방향으로 동시에 어려워지는 조건이다.

규모 3종과 시간 제약 3수준을 교차해 총 9개의 실험 조건을 만들고, 각 조건을 S-none, M-tight와 같이 규모-수준 형태로 표기한다.

5.3 비교 대상과 측정

비교 대상은 여섯이다. (i) VAA는 구성 휴리스틱만 적용한 초기해, (ii) Paper-SA-RL5는 원 모델의 재구현, (iii) Extended SA-RL5는 Paper-SA-RL5의 해 표현·이웃 구조·Q-learning 연산자 선택·SA 수락 규칙을 그대로 두고 평가와 목적식만 식 (16)으로 확장한 것이며, (iv)–(vi) GILS-uniform, GILS-tabular, GILS-DQN은 선택 정책만 바꾼 제안 방법의 세 변형이다. 제안 방법의 기본값은 GILS-uniform이고 나머지 두 변형은 학습 기반 선택의 효과를 보기 위한 것이다. 여기에 CP-SAT 결과를 함께 보고한다. 원 모델은 도착 시각과 납기를 다루지 않으므로 Paper-SA-RL5는 none 조건에서, Extended SA-RL5는 medium과 tight 조건에서 비교한다. none 조건에서는 납기 지연 항이 사라져 Extended SA-RL5가 Paper-SA-RL5와 같아진다.

인스턴스 seed는 학습·조정·시험 세 집합으로 서로소가 되게 나눈다. 학습 정책은 학습 집합에서만 훈련하고 λ 와 수락 규칙 같은 설계 값은 조정 집합에서만 고르므로 시험 집합의 성능이 부풀려지지 않는다. 주 해품질 비교(<Table 4>)는 조건당 시험 인스턴스 20개를 각각 5회 반복 실행한다. 인스턴스마다 난이도가 다르므로 여러 개가 필요하고, 알고리즘에 무작위성이 있으므로 같은 인스턴스도 여러 번 실행한다. 통제된 ablation(<Table 6>, <Table 7>)은 같은 엔진에서 구성요소만 떼어내는 짝지은 비교여서 인스턴스 간 난이도 편차가 상쇄되므로 조건당 5개만 사용하고, 선택 정책 비교(<Table 8>)는 주 비교와 같은 조건당 20개 인스턴스를 사용한다.

같은 인스턴스의 5회 반복은 서로 독립이 아니므로, 먼저 인스턴스별로 평균해 조건당 값 하나를 만든 뒤 짝지은 인스턴스 평균에 양측 Wilcoxon signed-rank test를 적용한다. 따라서 짝의 수 n 은 비교에 포함된 인스턴스 수를 넘지 않으며, 두 방법의 평균이 같아 차이가 0인 짝은 검정에서 제외된다.

본 논문은 해를 비교하는 기준을 세 가지로 엄격히 구분한다. **최적해**(optimal solution)는 CP-SAT가 반환한 해의 목적값이 증명된 하한과 일치하여 최적성이 증명된 해이다. **기준해**(reference solution)는 CP-SAT가 제한시간 안에 반환한 현재 최선해로, 최적성이 증명되지 않은 해를 포함하며 "최적"으로 부르지 않는다. **관측 최선해**(best observed solution)는 한 인스턴스에 대해 모든 방법, 모든 반복 횟수, CP-SAT 결과를 통틀어 관측된 가장 좋은 해로, 최적성에 대한 보장이 없다. 주 지표는 인스턴스별 격차 Δ_{bo} 이며, 해당 인스턴스에 대해 모든 방법과 모든 반복 횟수, CP-SAT 결과까지 통틀어 관측된 가장 좋은 목적값을 기준으로 삼는다. 대형 조건에서는 CP-SAT 기준해가 없어 최적해 대비 갭을 쓸 수 없기 때문이다.

Paper-SA-RL5와 Extended SA-RL5를 포함한 모든 메타휴리스틱의 종료 조건은 반복 횟수 1,000회로 동일한다. 한 반복은 선택된 연산자 하나로 후보해를 생성·평가하는 단계이며, GILS는 여기에 개선 시 하강 탐색을 더 수행한다. 원 모델은 CPU 시간으로 종료하지만 본 연구는 모든 방법에 같은 반복 횟수를 부여하였고, 반복당 계산량이 방법마다 다르므로 실행 시간은 <Table 4>에 함께 보고한다. CP-SAT는 인스턴스당 1회, 8 thread로 S에 300초(조건당 20개), M과 L에 600초(조건당 2개)를 부여하며, 최적성은 S-none 20개 전부와 S-medium 1개에서 증명된다. 보고하는 CP-SAT 계산 시간은 모형 구성과 solver 종료 처리를 포함한 wall-clock 시간이므로 명목 제한시간(600초)을 약간 넘을 수 있다. 실험은 Apple M2 칩(8 코어)과 16 GB 메모리를 갖춘 macOS 환경에서 Python 3.12와 OR-Tools 9.15로 수행하였다.

6. 실험 결과

6.1 해 품질

<Table 4>에 20개 인스턴스에 대한 시험 결과를 요약한다. CP-SAT가 기준해를 제공한 실험 조건에서 GILS는 이에 근접하며, 기본 선택 정책인 균등 선택 기준으로 그 격차는 평균 0.06–0.25%이다(학습 선택 정책을 포함한 전체 변형은 0.06–0.50%). 최적성이 증명된 S-none 20개 인스턴스에서 균등 선택 GILS는 최적해보다 평균 0.25% 높다. 같은 선택 정책 기준으로 VAA 대비 격차는 평균 2.66%($n = 180, p < 0.0001$), SA-RL5 대비 격차는 1.38%($n = 60, p < 0.0001$)이다. medium과 tight 조건에서 Extended SA-RL5 대비 격차는 평균 0.89%($n = 120, p < 0.0001$)이다. 실행 시간은 S/M/L에서 각각 0.09, 0.55, 3.17초이다. CP-SAT가 기준해를 반환한 조건에서 CP-SAT의 평균 계산 시간은 S-none 40초, S-medium 245초, S-tight 250초, M-none 606초로 같은 조건의 GILS(각각 0.09, 0.09, 0.09, 0.48초)보다 100배 이상 길며, M의 시간 제약 조건과 L의 모든 조건에서는 CP-SAT가 제한시간 안에 실행 가능해를 반환하지 못했다.

GILS는 개선 이동 뒤 하강 탐색을 추가로 수행하므로 같은 반복 횟수가 같은 계산량을 뜻하지는 않는다. 이를 통제하기 위해, 각 시험 실행(조건·인스턴스·반복)에서 GILS가 실제로 사용한 실행 시간을 같은 실행의 SA-RL5(시간 제약 조건은 Extended SA-RL5)에 그대로 부여하고 시간이 다할 때까지 반복하게 한 동일 wall-clock 비교를 추가로 수행하였다(<Table 5>). L에서는 SA-RL5가 평균 2,020회로 반복 1,000회 비교보다 약 2배의 탐색을 수행하지만(S에서는 GILS가 더 빨라 586회), GILS는 모든 규모에서 동일 시간의 SA-RL5보다 좋은 해를 찾았고(전체 평균 1.08%, $p < 0.0001$) SA-RL5가 앞선 인스턴스는 180개 중 하나도 없었다. 따라서 GILS의 성능 향상은 추가 계산량이 아니라 탐색 구조에서 비롯된다.

Table 4. Test results over 20 instances per experimental condition (20 instances $\times$ 5 replications). Δ_{bo} is the mean gap to the best observed solution and time is the mean per run. The vs CP-SAT column is computed only on the subset for which CP-SAT returned a reference (20 instances per S condition, 2 for M-none); optimality was proven for all 20 S-none instances and one S-medium instance. On that subset the mean CP-SAT runtime is 179 s (S) and 606 s (M-none).

Condition	Method	Mean obj. $\pm$ s.d.	$\Delta_{bo}(\%)$	vs CP-SAT(%)	Time(s)
S-none	VAA	1497.5 $\pm$ 400.3	6.61	+6.61	0.00
	Paper-SA-RL5	1423.3 $\pm$ 383.6	1.04	+1.04	0.15
	GILS-uniform	1412.5 $\pm$ 381.8	0.25	+0.25	0.09
	GILS-tabular	1413.7 $\pm$ 382.5	0.32	+0.32	0.11
	GILS-DQN	1413.4 $\pm$ 382.1	0.30	+0.30	0.23
S-medium	VAA	5447.5 $\pm$ 1468.9	3.90	+3.90	0.00
	Extended-SA-RL5	5289.1 $\pm$ 1428.9	0.71	+0.71	0.17
	GILS-uniform	5258.8 $\pm$ 1412.7	0.15	+0.15	0.09
	GILS-tabular	5262.0 $\pm$ 1409.6	0.24	+0.24	0.12
	GILS-DQN	5275.2 $\pm$ 1412.5	0.50	+0.50	0.23
S-tight	VAA	9276.8 $\pm$ 2387.6	2.91	+2.91	0.00
	Extended-SA-RL5	9057.4 $\pm$ 2224.3	0.60	+0.60	0.17
	GILS-uniform	9012.8 $\pm$ 2205.5	0.13	+0.13	0.09
	GILS-tabular	9016.9 $\pm$ 2206.4	0.17	+0.17	0.12
	GILS-DQN	9024.3 $\pm$ 2209.0	0.26	+0.26	0.24
M-none	VAA	3030.9 $\pm$ 903.6	3.73	+4.80	0.00
	Paper-SA-RL5	2976.4 $\pm$ 864.4	1.86	+0.99	0.55
	GILS-uniform	2928.8 $\pm$ 844.0	0.27	+0.06	0.48
	GILS-tabular	2929.8 $\pm$ 844.4	0.30	+0.10	0.58
	GILS-DQN	2930.2 $\pm$ 843.9	0.32	+0.14	0.77
M-medium	VAA	23025.5 $\pm$ 4075.4	2.57	—	0.00
	Extended-SA-RL5	22843.1 $\pm$ 4012.0	1.72	—	0.57
	GILS-uniform	22514.6 $\pm$ 3960.1	0.25	—	0.52
	GILS-tabular	22517.8 $\pm$ 3967.4	0.26	—	0.65
	GILS-DQN	22542.4 $\pm$ 3958.6	0.38	—	0.75
M-tight	VAA	38903.7 $\pm$ 11283.5	1.24	—	0.01
	Extended-SA-RL5	38786.7 $\pm$ 11087.7	0.90	—	0.66
	GILS-uniform	38496.5 $\pm$ 11061.4	0.11	—	0.65
	GILS-tabular	38512.9 $\pm$ 11062.6	0.15	—	0.77
	GILS-DQN	38542.6 $\pm$ 11072.4	0.23	—	0.78
L-none	VAA	5492.3 $\pm$ 1482.2	2.18	—	0.02
	Paper-SA-RL5	5479.7 $\pm$ 1449.5	1.95	—	1.92
	GILS-uniform	5384.0 $\pm$ 1423.9	0.17	—	3.38
	GILS-tabular	5386.4 $\pm$ 1424.2	0.21	—	3.74
	GILS-DQN	5384.9 $\pm$ 1424.5	0.18	—	3.09
L-medium	VAA	55611.1 $\pm$ 18087.3	1.55	—	0.02
	Extended-SA-RL5	55539.7 $\pm$ 17673.9	1.44	—	1.95
	GILS-uniform	54826.5 $\pm$ 17528.3	0.09	—	3.21
	GILS-tabular	54830.9 $\pm$ 17523.0	0.11	—	3.60
	GILS-DQN	54839.1 $\pm$ 17523.4	0.12	—	3.05
L-tight	VAA	119671.9 $\pm$ 32475.3	0.78	—	0.02
	Extended-SA-RL5	119637.8 $\pm$ 31833.7	0.74	—	1.88
	GILS-uniform	118865.0 $\pm$ 31786.4	0.05	—	2.91
	GILS-tabular	118866.6 $\pm$ 31780.4	0.06	—	3.38
	GILS-DQN	118897.8 $\pm$ 31779.3	0.08	—	3.35

Table 5. Budget-fairness check (20 instances $\times$ 5 replications per condition). SA-RL5 denotes Paper-SA-RL5 on none and Extended SA-RL5 on medium/tight. Gain is the mean relative objective difference in favor of GILS-uniform; SA-RL5 wins counts instances where the time-matched SA-RL5 has the better replication mean. Two-sided Wilcoxon on per-instance replication means, $p < 0.0001$ in every row.

Size	n	GILS time (s)	SA-RL5 iterations (same time)	Gain vs 1,000 it. (%)	Gain vs same time (%)	SA-RL5 wins
S	60	0.09	586	+0.61	+1.23	0
M	60	0.55	1,102	+1.28	+1.24	0
L	60	3.17	2,020	+1.27	+0.76	0
All	180	1.27	1,236	+1.05	+1.08	0

6.2 핵심 구성요소 분석: 성능은 어디에서 오는가

세 가지 통제된 ablation(반복 횟수 1,000회 고정)으로 엔진을 분해한다.

연산자 집합. 선택 정책을 균등 선택으로 고정하고 연산자 집합만 기본(7종)/ 핵심(+g1,g2)/ 전체(+g3,g4)로 바꾸면, 기본에서 핵심으로 갈 때 Δ_{bo} 가 9개 실험 조건 전부에서 낮아지고(<Figure 2>) 짝지은 Wilcoxon(<Table 6>)에서도 g1, g2 추가의 효과가 뚜렷하다($p < 0.0001$). 반면 g3, g4를 더한 효과는 +0.025%p로 작고 전체 45쌍에서의 유의성도 경계 수준이며($p = 0.032$), 시간 제약 유무로 나누면 유의하지 않아($p = 0.09, 0.12$) 보조적인 효과로 본다. S-medium, S-tight, L-tight에서는 오히려 전체 집합의 Δ_{bo} 가 0.02%p 이내에서 근소하게 높다. 따라서 유도 연산자의 이득은 대부분 g1, g2에서 나온다.

Table 6. Operator-pool ablation (5 instances $\times$ 5 replications per condition over 9 conditions, the number of iterations fixed at 1,000; two-sided Wilcoxon on per-instance replication means, hence at most 45 pairs, with zero differences excluded from n ; positive mean favors the richer operator set).

Contrast	n	Gain(%p)	p
generic $\rightarrow$ critical (add g1, g2)	45	+0.128	<0.0001
critical $\rightarrow$ full (add g3, g4)	45	+0.025	0.0320
generic $\rightarrow$ full (all guided)	45	+0.153	<0.0001




Figure 2. Mean gap to the best observed solution by operator set.

엔진 구성요소. 연산자 집합을 전체로, 선택 정책을 균등 선택으로 고정한 최종 엔진에서 구성요소를 하나씩 제거하거나 SA 수락 규칙과 reheating을 추가하면(<Table 7>, <Figure 3>) 섭동 재시작 제거에 따른 악화가 가장 크고 시간 제약 유무와 관계없이 유의하다. 하강 탐색 제거의 악화(+0.041%p, $p = 0.003$)는 유의하지만 재시작 제거의 약 1/9 수준이다. 무작위 초기해의 악화(+0.043%p, $p = 0.048$)는 경계 수준이고 시간 제약 유무로 나누면 유의하지 않으므로, VAA 초기해의 기여는 작고 보조적이다. SA 수락 규칙과 reheating을 추가하면 목적값이 오히려 나빠져, 조정 집합에서 정한 greedy 수락 규칙을 시험 집합에서도 뒷받침한다.

Table 7. Engine-component ablation (5 instances $\times$ 5 replications per condition over 9 conditions; one change at a time to the final greedy-acceptance engine, relative objective degradation after the change; two-sided Wilcoxon on per-instance replication means, hence at most 45 pairs, with zero differences excluded from n).

Change to the final engine	n	Degradation(%p)	p
remove best-improvement descent	45	+0.041	0.0032
remove kick restart	45	+0.365	<0.0001
random start instead of VAA	45	+0.043	0.0482
add SA acceptance + reheating	45	+0.027	0.0014




Figure 3. Objective degradation when a component is removed from, or SA acceptance is added to, the final engine.

6.3 보조 분석: 학습 기반 연산자 선택

연산자 집합과 구성요소를 전체로 고정하고 선택 정책만 바꾸면(<Table 8>), 어떤 학습 정책도 균등 선택보다 좋지 않다. tabular Q-learning은 균등 선택보다 평균 0.038%p, transfer DQN은 0.101%p 나쁘며 둘다 유의하다. 반복 횟수를 50–3,000회로 바꾸어도 모든 반복 횟수에서 균등 선택의 격차가 가장 작고, 3,000회에서만 tabular가 균등 선택에 근접한다(0.13% 대 0.12%, <Figure 5>). 이러한 결과는 무제약 조건만으로도 성립하므로(균등 선택 대비 tabular $-0.049\%p$, $p = 0.0002$; DQN $-0.041\%p$, $p = 0.002$) 시간 제약 확장 때문에 나타난 결과가 아니다.

Table 8. Effect of the selection policy (20 instances $\times$ 5 replications per condition over 9 conditions, 1,000 iterations; two-sided Wilcoxon on per-instance replication means, hence at most 180 pairs, with zero differences excluded from n ; positive mean favors the first method).

Comparison	n	Mean diff.(%p)	p	Verdict
tabular vs uniform	180	-0.038	<0.0001	Tabular worse
tabular vs DQN	180	$+0.063$	<0.0001	DQN worse
uniform vs DQN	179	$+0.101$	<0.0001	DQN worse

6.4 납기지연 가중치 민감도

식 (16)은 총 작업완료시간과 총 납기지연이라는, 척도가 서로 다른 두 시간 성분을 합치므로, 조정 집합에서 $\lambda \in \{0, 0.25, 0.5, 1, 2, 4, 8\}$ 값을 바꿔가며 탐색한다. 물리적 총 작업완료시간과 총 납기지연을 인스턴스별로 min-max 정규화해 평균한다(<Figure 4>). 납기지연 감소의 대부분은 $\lambda = 0$ 에서 1 사이에서 일어나고 이후에는 그 폭이 줄어든다. 전체 탐색 구간에서 규모별 평균 총 작업완료시간은 0.6–1.4% 상승하고 평균 납기지연은 0.9–3.1% 하락한다. $\lambda = 1$ 을 채택한다: 완만한 총 작업완료시간 비용으로 납기지연이 거의 최소에 이르며, 총 작업완료시간과 납기지연에 단위 시간당 동일한 벌점 계수를 부여한다. 다만 $C_{\max}$ 는 단

일 최댓값이고 $\sum_q T_q$ 는 여러 트럭의 합이므로 계수가 같다고 두 성분이 목적식에 미치는 실질적 영향까지 같은 것은 아니다. λ 는 운영자가 총 작업완료시간 대비 납기 준수를 얼마나 중시하는지를 나타내는 관리적 선호(managerial preference) 파라미터이며, 실제 적용에서는 운영 여건에 맞게 조정할 수 있다. 이 탐색은 시험이 아닌 조정 인스턴스를 사용한 설계 정당화이다.




Figure 4. Normalized makespan-tardiness trade-off on tuning instances.

7. 논의

학습 기반 선택 정책이 균등 선택 대비 이득을 주지 못한 것은 학습 일반에 대한 결론이 아니라 본 논문의 탐색 구조가 낳은 결과다. 후보 하나의 평가에 수십-백수십 마이크로초(μs)밖에 들지 않아 연산자를 잘 고르는 것보다 많이 시도하는 편이 유리하고, 모든 신규 최선해 뒤에 결정론적 하강 탐색이 따라붙어 어떤 연산자로 그 지점에 이르렀는지의 차이를 상당 부분 흡수한다. 반복 횟수별 격차 곡선도 1,000회 이후의 추가 개선이 작음을 보인다(조건당 5개 인스턴스에서 균등 선택의 격차는 1,000회 0.22%, 3,000회 0.12%이고, 45개 인스턴스 중 33개에서 개선 폭이 0.1%p 미만이다). 정체 탈출은 섭동 재시작이 맡으므로 SA 수락 규칙과 reheating의 역할은 이와 겹치며, 조정 집합 비교와 시험 집합 ablation에서 이 둘이 해 품질을 높이지 않아 최종 VAA-GILS에서 제외하였다(4장, <Table 7>). 즉 본 문제에서 성능의 본질은 학습된 선택 정책이나 확률적 수락 규칙이 아니라 섭동 재시작, 유도 연산자, 결정론적 하강 탐색에 있다.

선택 정책이 예측할 대상이 마땅치 않다는 점도 작용한다. 본 문제의 인스턴스는 정적이고 모든 도착 시각이 최적화 이전에 알려져 있어, 실행 도중 새로 드러나 정책이 활용할 정보가 없다. 도착 정보가 시간에 따라 공개되는 동적 도크 운영이나 이동 하나의 평가가 비싼 시뮬레이션 기반 모형에서는 판단이 달라질 수

있다. 따라서 본 결과의 함의는 학습이 무용하다는 것이 아니라 비교 조건에 있다. 학습 기반 선택 정책은 동일한 엔진과 동일한 반복 횟수 아래 균등 선택과 견주어야 하며, 그 통제가 없으면 하강 탐색·재시작·강한 연산자 집합의 이득이 정책의 성과로 잘못 귀속될 수 있다.

8. 결론

본 연구는 부분 하역된 병행 트럭이 출고 운송 트럭으로 전환되고 다른 트럭의 이송 화물을 기다리는 선행 관계가 트럭별 도착 시각·연성 납기와 결합하면서 지원이 공유 목적지를 따라 전파되는 구조를, 저자가 아는 한 처음으로 MILP·CP-SAT 모형으로 정식화하고 목적식의 유효 하한을 제시하였다. CP-SAT 기준해가 있는 실험 조건에서 VAA-GILS의 목적값은 해당 기준해 대비 평균 0.06–0.25%였고(소형 무제약 조건의 20개 인스턴스는 CP-SAT가 모두 최적성을 증명하였으며 최적해 대비 평균 격차는 0.25%였다), CP-SAT가 600초 안에 실행 가능해를 찾지 못한 대형 시간 제약 조건에서도 약 3초 안에 VAA와 Extended SA-RL5보다 좋은 해를 제공하였다. 동일 wall-clock 예산에서도 VAA-GILS는 SA-RL5보다 일관되게 우수하여, 성능 향상이 추가 계산량이 아니라 탐색 구조에서 비롯됨을 확인하였다. ablation은 성능이 섭동 재시작, 유도 연산자, 하강 탐색이라는 결정론적 구조에서 비롯되며, 학습 기반 연산자 선택과 확률적 수락 규칙은 이 환경에서 실용적 이득을 주지 않아 최종 알고리즘은 greedy 수락 규칙을 사용한다. 향후에는 도착 정보가 실시간으로 공개되는 동적 문제, 대형 시간 제약 조건을 위한 더 강한 하한, 산업 데이터를 활용한 사례 연구가 필요하다.

부록 A. Transfer DQN 구현 세부

transfer DQN은 매 반복 11개 연산자 집합에서 하나를 고른다. Q-network는 27차원 규모 불변 상태를 연산자별 Q값으로 사상하는 MLP로, 64 unit의 hidden layer 2개와 ReLU를 쓴다. 학습은 용량 100,000의 replay buffer를 사용하며, 500 transition warm-up 후 매 step 1회 gradient step으로 Huber(smooth- L_1) temporal-difference loss를 Adam (learning rate 10^{-3} , discount $\gamma = 0.9$)으로 최소화한다. mini-batch는 64, target network는 500 step마다 동기화한다. reward는 shaped signal(현재 최선해 갱신 2, 비악화 1, 그 외 0)이다. agent는 학습 집합(S/M 규모, 모든 화물 분포·시간 제약 조건)에서 500회 실행으로 오프라인 학습(ϵ -greedy) 후, 시험 인스턴스에 zero-shot ($\epsilon = 0$, 갱신 없음)으로 적용한다. 결과가 균등 선택 대비 개선이 없다는 것이므로, 재현·강화가 가능하도록 network·학습 스크립트·seed를 공개한다.




Figure 5. Mean gap to the best observed solution versus the number of iterations.

생성형 AI 활용 내역

본 논문의 연구 및 작성 과정에서 저자는 OpenAI Codex(GPT-5, OpenAI)와 Claude Code(Anthropic)를 코드 작성 및 디버깅 보조와 논문의 문장 표현 및 가독성 개선을 위해 활용하였다. 생성형 AI의 도움을 받은 내용은 저자가 검토 및 수정하였으며, 논문의 모든 내용과 결과에 대한 책임은 저자에게 있다.

참고문헌

- Assadi, M. T. and Bagheri, M.(2016), Differential Evolution and Population-Based Simulated Annealing for Truck Scheduling Problem in Multiple Door Cross-Docking Systems, *Computers & Industrial Engineering*, 96, 149-161.
- Bodnar, P., de Koster, R., and Azadeh, K.(2017), Scheduling Trucks in a Cross-Dock with Mixed Service Mode Dock Doors, *Transportation Science*, 51(1), 112-131.
- Boysen, N. and Flidner, M.(2010), Cross Dock Scheduling: Classification, Literature Review and Research Agenda, *Omega*, 38(6), 413-422.
- Joo, C. M. and Kim, B. S.(2013), Scheduling Compound Trucks in Multi-Door Cross-Docking Terminals, *International Journal of Advanced Manufacturing Technology*, 64, 977-988.
- Karimi-Mamaghan, M., Mohammadi, M., Pasdeloup, B., and Meyer, P.(2023), Learning to Select Operators in Meta-Heuristics: An Integration of Q-Learning into the Iterated Greedy Algorithm for the Permutation

- Flowshop Scheduling Problem, *European Journal of Operational Research*, 304(3), 1296-1330.
- Kirkpatrick, S., Gelatt, C. D., and Vecchi, M. P.(1983), Optimization by Simulated Annealing, *Science*, 220(4598), 671-680.
- Konur, D. and Golias, M. M.(2013a), Analysis of Different Approaches to Cross-Dock Truck Scheduling with Truck Arrival Time Uncertainty, *Computers & Industrial Engineering*, 65(4), 663-672.
- Konur, D. and Golias, M. M.(2013b), Cost-Stable Truck Scheduling at a Cross-Dock Facility with Unknown Truck Arrivals: A Meta-Heuristic Approach, *Transportation Research Part E*, 49(1), 71-91.
- Ladier, A.-L. and Alpan, G.(2016), Robust Cross-Dock Scheduling with Time Windows, *Computers & Industrial Engineering*, 99, 16-28.
- Larbi, R., Alpan, G., Baptiste, P., and Penz, B.(2011), Scheduling Cross Docking Operations under Full, Partial and No Information on Inbound Arrivals, *Computers & Operations Research*, 38(6), 889-900.
- Li, M., Hao, J.-K., and Wu, Q.(2024), A Flow Based Formulation and a Reinforcement Learning Based Strategic Oscillation for Cross-Dock Door Assignment, *European Journal of Operational Research*, 312(2), 473-492.
- Li, Y., Mohammadi, M., Zhang, X., Lan, Y., and van Jaarsveld, W.(2026), Integrated Trucks Assignment and Scheduling Problem with Mixed Service Mode Docks, *European Journal of Operational Research*, 333(1), 117-137.
- Lourenço, H. R., Martin, O. C., and Stützle, T.(2019), Iterated Local Search: Framework and Applications, In Gendreau, M. and Potvin, J.-Y.(Eds.), *Handbook of Metaheuristics*, Springer, Cham, 129-168.
- Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., and Hassabis, D.(2015), Human-Level Control through Deep Reinforcement Learning, *Nature*, 518, 529-533.
- Molavi, D., Shahmardan, A., and Sajadieh, M. S.(2018), Truck Scheduling in a Cross Docking Systems with Fixed Due Dates and Shipment Sorting, *Computers & Industrial Engineering*, 117, 29-40.
- Nowak, M. and Puladi, S.(2025), Value of Operational Flexibility in Cross-Docking, *Computers & Industrial Engineering*, 209, 111423.
- Pan, F., Fan, T., Qi, X., Chen, J., and Zhang, C.(2021), Truck Scheduling for Cross-Docking of Fresh Produce with Repeated Loading, *Mathematical Problems in Engineering*, 2021, 5592122.

- Rijal, A., Bijvank, M., and de Koster, R.(2019), Integrated Scheduling and Assignment of Trucks at Unit-Load Cross-Dock Terminals with Mixed Service Mode Dock Doors, *European Journal of Operational Research*, 278(3), 752-771.
- Ropke, S. and Pisinger, D.(2006), An Adaptive Large Neighborhood Search Heuristic for the Pickup and Delivery Problem with Time Windows, *Transportation Science*, 40(4), 455-472.
- Shahmardan, A. and Sajadieh, M. S.(2020), Truck Scheduling in a Multi-Door Cross-Docking Center with Partial Unloading: Reinforcement Learning-Based Simulated Annealing Approaches, *Computers & Industrial Engineering*, 139, 106134.
- Theophilus, O., Dulebenets, M. A., Pasha, J., Lau, Y.-y., Fathollahi-Fard, A. M., and Mazaheri, A.(2021), Truck Scheduling Optimization at a Cold-Chain Cross-Docking Terminal with Product Perishability Considerations, *Computers & Industrial Engineering*, 156, 107240.
- Van Belle, J., Valckenaers, P., and Cattrysse, D.(2012), Cross-Docking: State of the Art, *Omega*, 40(6), 827-846.
- Van Belle, J., Valckenaers, P., Vanden Berghe, G., and Cattrysse, D.(2013), A Tabu Search Approach to the Truck Scheduling Problem with Multiple Docks and Time Windows, *Computers & Industrial Engineering*, 66(4), 818-826.
- Watkins, C. J. C. H. and Dayan, P.(1992), Q-Learning, *Machine Learning*, 8, 279-292.
- Xi, X., Liu, C., Wang, Y., and Lee, L. H.(2020), Two-Stage Conflict Robust Optimization Models for Cross-Dock Truck Scheduling Problem under Uncertainty, *Transportation Research Part E*, 144, 102123.