

Abstract

We study truck scheduling in a multi-door cross-dock where a compound truck is partially unloaded, then departs as the carrier for its retained destination. Prior studies imposed temporal constraints on trucks with fixed roles or on fully unloading compound trucks, whereas partial-unloading models minimize makespan with all trucks available at time zero. We develop MIP and CP-SAT formulations that minimize makespan and total tardiness under release times, soft due dates, carrier conversion, and freight-transfer precedence, so that late arrivals propagate tardiness through carriers waiting for freight. To our knowledge, no previous model combines these temporal constraints with retained-destination partial unloading and carrier conversion. VAA-GILS combines Vogel-style construction with bottleneck-guided local improvement. Against 62 CP-SAT references, its mean gap is 0.10–0.23% in under 0.5 s; on 20 small unconstrained proven-optimal instances, it averages 0.23% above optimum. Where CP-SAT finds no feasible schedule within 600 s, it outperforms all compared methods.

Keywords: Cross-Docking, Compound Truck, Release Time, Soft Due Date, Iterated Local Search, Constraint Programming

도착 시각(release time)과 연성 납기(soft due date)를 갖는 입출고 병행 트럭 크로스도킹 스케줄링: CP-SAT

기준해 비교를 동반한 병목 유도 반복 지역탐색

Compound-Truck Cross-Docking Scheduling with Release Times and Soft Due Dates: A Bottleneck-Guided Iterated Local Search with CP-SAT Benchmarking

1. 서론

크로스도킹은 입고 화물을 창고에 보관하지 않고 곧바로 출고트럭으로 환적하여 재고와 리드타임을 줄이는 물류 방식이다(Boysen and Fliedner, 2010; Van Belle et al., 2012). Joo 와 Kim(2013)이 도입한

병행 트럭(compound truck)은 한 대의 트럭이 입고와 출고 역할을 겸하는 형태이며, Shahmardan 과 Sajadieh(2020)가 발전시킨 부분 하역 변형에서는 여러 목적지 화물을 싣고 도착한 뒤 한 목적지의 화물은 유지하고 나머지만 **부분적으로** 하역하며, 이후 해당 목적지의 나머지 화물을 적재해 출고 운송 트럭으로 출발한다. 부분 하역은 전량 하역 대비 총 작업완료시간(makespan)을 크게 줄이는 것으로 보고되어 LTL(Less-Than-Truckload, 소량 화물 운송) 통합 네트워크에서 실용적 매력이 크다.

부분 하역 병행 트럭 모형(Shahmardan and Sajadieh, 2020)의 두 가정이 현실성을 제약한다. 첫째, 모든 트럭이 시각 0 에 가용하다고 가정하지만 실제 도크에서는 트럭마다 예약 도착 시각(release time)이 다르다. 일반 크로스도킹 연구에서도 트럭 도착은 시간창(time window)이나 도착 구간으로 주어지는 것으로 다루어지며(Van Belle 등, 2013; Konur and Golias, 2013a; Ladier and Alpan, 2016), 도착 정보를 얼마나 알고 있는지가 스케줄 품질에 영향을 준다(Larbi 등, 2011). 둘째, 목적식이 순수 총 작업완료시간이지만 출고트럭의 출발은 위반 시 비용이 발생하는 납기(due date)에 묶여 있다. 출고 납기는 경성 제약으로 부과되거나(Molavi 등, 2018) 납기지연(tardiness)이나 지연 출발 비용으로 목적식에 반영되어 왔다(Van Belle 등, 2013; Rijal 등, 2019; Theophilus 등, 2021). 부분 하역 모형이 이 두 요소를 빼면 부분 하역의 이점이 실제 도착 시각과 출발 일정 아래에서도 유지되는지 평가할 수 없으므로, 두 가정을 완화한 모형이 필요하다.

도착 시각, 시간창, 납기지연은 일반 크로스도킹 스케줄링에서 이미 연구되어 왔고(Van Belle et al., 2013; Assadi and Bagheri, 2016; Bodnar et al., 2017; Molavi et al., 2018; Rijal et al., 2019; Li et al., 2026), 전량 하역 후 다시 적재하는 병행 트럭에도 트럭별 도착 시각(Ozden and Saricicek, 2019; Abtahi,

2025)과 연성 시간창(Ozden and Saricicek, 2019)이 도입되었다. 그러나 부분 하역 병행 트럭 설정은 temporal constraint 의 의미를 바꾼다. 병행 트럭은 순수 입고트럭도 출고트럭도 아니다. 부분 하역 후 한 목적지의 화물을 유지하고, 해당 목적지로 들어오는 이송 화물을 기다린 뒤 비로소 출고 운송 트럭으로 출발한다. 이 부분 하역 변환은 하나의 precedence chain — 도착 → 부분 하역 → 유지 화물 → 이송 대기 → 출고 — 을 만들고, 이 chain 은 트럭들을 공유 목적지를 통해 결합한다. 따라서 도착 시각을 추가한다고 해서 한 트럭의 시작 시각만 늦어지는 것은 아니다. 늦은 도착은 해당 트럭의 이송 화물에 의존하는 모든 출고 운송 트럭으로 전파되고, 연성 납기(soft due date)는 이 연쇄 지연을 납기지연 비용으로 바꾼다. 본 연구의 기여는 이 상호작용 — 알려진 도착 시각과 연성 납기가 부분 하역 후 출고 운송 트럭으로 전환되는 과정과 결합되는 방식 — 을 정식화하고 분석하는 것이며, 저자가 아는 한 이 결합은 이전에 모형화된 바 없다.

본 논문의 기여와 기존 연구 대비 차별성은 다음 세 가지이며, 대표 연구와의 비교는 <Table 1>에 정리하였다. 첫째, 문제 정식화의 차별성이다. 도착 시각이나 납기를 다룬 기존 연구(Van Belle 등, 2013; Assadi and Bagheri, 2016; Bodnar 등, 2017; Rijal 등, 2019; Theophilus 등, 2021; Li 등, 2026)는 모두 입고와 출고 역할이 고정된 트럭을 전제한다. 병행 트럭에 도착 시각을 둔 Ozden 과 Saricicek(2019), Abtahi(2025)는 병행 트럭이 화물을 모두 하역한 뒤 다시 적재하는 구조이고, 부분 하역 병행 트럭 모형(Shahmardan and Sajadieh, 2020)과 병행 트럭 운영의 유연성을 다룬 Nowak 과 Puladi(2025)는 모든 트럭이 시각 0 에 가용하다고 보고 총 작업완료시간만 최소화한다. 즉 시간 제약을 다룬 계열과 부분 하역 병행 트럭 계열은 따로 발전해 왔다. 본 연구는 지정 목적지의 화물을 유지한 채 부분 하역한

병행 트럭이 그 목적지의 운송 트럭으로 전환되고, 다른 트럭에서 오는 이송 화물을 모두 받은 뒤에야 출발할 수 있는 구조에 트럭별 도착 시각과 연성 납기를 결합한 모형을 저자가 아는 한 처음 제시한다. 이 모형은 독립적인 스케줄 평가기와 일치하는 big- M MILP 및 reified CP-SAT 로 정식화한다. 이 결합에서는 한 트럭의 늦은 도착이 공유 목적지를 통해 다른 운송 트럭의 납기지연으로 전파되므로, 두 계열 가운데 어느 한쪽 모형의 단순한 확장으로는 나타나지 않는 지연 구조가 생긴다. 둘째, 해법의 차별성이다. Shahmardan 과 Sajadieh(2020)의 SA-RL5 는 한 반복에 이동 하나를 simulated annealing 으로 수락하는 순수 SA 이고, 최근의 학습형 메타휴리스틱(Karimi-Mamaghan 등, 2023; Li 등, 2026)은 연산자 선택 자체를 학습한다. 본 연구는 원 모델의 VAA 구성 휴리스틱과 기본 이웃 구조에, 병목 트럭과 납기지연이 큰 트럭을 직접 겨냥하는 병목 유도 연산자(bottleneck-guided operator), 개선 시 적용하는 최선개선 하강 탐색(best-improvement descent), 섭동 재시작(kick restart)을 결합한 VAA-GILS 를 제안하며, 이 해법은 같은 반복 횟수뿐 아니라 같은 실행 시간에서도 원 모델 계열의 해법보다 좋은 해를 찾는다. 셋째, 검증 방식의 차별성이다. 소형 무제약 조건의 20 개 인스턴스 전부에서 CP-SAT 로 최적성을 증명하여 휴리스틱의 최적해 대비 격차를 제시하고, 최적해와 기준해, 관측 최선해를 구분하여 보고한다. 또한 학습 기반 연산자 선택을 같은 엔진, 같은 반복 횟수의 균등 선택과 비교하는 통제된 ablation 으로, 강한 지역탐색이 적용된 본 해법에서는 학습 기반 선택 정책의 추가적인 이득이 제한적임을 보조적으로 확인한다.

관련 연구. 크로스도킹 도크 스케줄링은 Boysen 과 Flidner(2010)의 분류와 Van Belle 등(2012)의 연구 동향 정리에 요약되어 있다. 기존 입고트럭과 출고트럭을 다루는 결정론적 모형들은 time window 와

납기지연(Van Belle 등, 2013), ready time 과 조기완료 및 납기지연(Assadi and Bagheri, 2016), mixed-service door(Bodnar 등, 2017), 경성 납기(hard due date)(Molavi 등, 2018), 트럭 스케줄링과 도어 배정의 통합(Rijal 등, 2019), 트럭 도착 시각과 지연 출발 비용(Theophilus 등, 2021)처럼 시간 제약을 이미 반영한다. 다만 이들은 모두 입고트럭과 출고트럭을 구분하며, 부분 하역 후 출고 운송 트럭으로 전환되는 트럭은 모형화하지 않는다. 병행 트럭 계열의 후속 연구는 드물다. Ozden 과 Saricicek(2019)은 입고, 출고, 병행 트럭의 도착 시각을 서로 다르게 두고 출고 적재의 연성 시간창에 대한 조기완료와 납기지연을 최소화하지만, 병행 트럭은 입고 도어에서 화물을 하역한 뒤 출고 도어로 이동해 다시 적재하므로 화물을 유지한 채 운송 트럭으로 전환되는 구조는 없다. Abtahi(2025)도 병행 트럭을 포함한 모든 트럭의 도착 시각을 서로 다르게 두지만, 병행 트럭은 하역 후 출고 구역으로 이동해 새 화물을 적재하며 목적식은 납기지연이 아니라 주어진 작업 시간 안에 적재되는 제품 수의 최대화이다. Nowak 과 Puladi(2025)는 전량 하역 뒤 다시 적재되는 병행 트럭을 다루되 도착 시각과 납기를 두지 않고, Pan 등(2021)은 출고트럭의 반복 적재를 허용하되 모든 트럭이 시각 0 에 가용하다고 가정한다. 도착 정보가 불확실한 경우를 다룬 연구도 있으나(Larbi 등, 2011; Konur and Golias, 2013a, 2013b; Ladier and Alpan, 2016; Xi 등, 2020), 본 모형은 결정론적이며 각 도착 시각이 스케줄 구성 시점에 알려져 있다고 본다.

가장 가까운 연구는 Li 등(2026)으로, 무인 배송센터(distribution center)의 mixed service mode dock 에서 통합 트럭 배정과 스케줄링을 Q-learning 기반 ALNS(adaptive large neighborhood search; Ropke and Pisinger, 2006)로 풀고 시간창과 납기지연, 총 작업완료시간을 함께 다룬다. 그러나 그

유연성은 도어 수준에 있어 도어가 적재 전용, 하역 전용, 혼합 모드 중 하나를 고르고 트럭은 순수 입고트럭이나 출고트럭으로 고정되며 화물은 저장 구역을 경유해 운반되는 반면, 본 문제의 유연성은 트럭 수준에 있어 부분 하역된 병행 트럭이 특정 목적지의 운송 트럭으로 전환되고 화물은 도어 간에 직접 이송된다. 한편 학습 기반 탐색 제어가 메타휴리스틱을 개선한다는 보고가 많으나(Karimi-Mamaghan 등, 2023; Li 등, 2024), 본 연구는 강한 지역탐색이 적용된 조건에서는 학습 기반 선택 정책의 추가적인 이득이 제한적임을 통제된 비교를 통해 확인한다. 대표 연구와 본 연구의 문제 및 해법 차이는 <Table 1>에 요약하였다.

Table 1. Positioning of this study against representative cross-docking truck scheduling studies. Temporal constraints are truck arrival, release, due-date, or departure-time restrictions; "—" in the partial-unloading column denotes models without compound trucks.

Study	Truck roles	Partial unloading	Temporal constraints	Objective	Solution method
Van Belle et al. (2013)	Inbound/outbound	—	Time windows	Travel time + tardiness	Tabu search
Assadi and Bagheri (2016)	Inbound/outbound	—	Ready times	Earliness + tardiness	MILP, DE, PBSA
Bodnar et al. (2017)	Inbound/outbound; mixed-service doors	—	Time windows	Cost including tardiness	ALNS
Ozden and Saricicek (2019)	Inbound/outbound/compound; separate receiving and shipping doors	No (full unloading)	Arrival times, soft time windows	Earliness + tardiness	MIP, SA, TS
Rijal et al. (2019)	Inbound/outbound; mixed-service doors	—	Arrival and departure times	Tardiness + storage + travel cost	ALNS
Shahmardan and Sajadieh (2020)	Compound + outbound;	Yes	None (all at time 0)	Makespan	Heuristic, RL-based SA

Study	Truck roles	Partial unloading	Temporal constraints	Objective	Solution method
	mixed-service doors				
Theophilus et al. (2021)	Inbound/outbound	—	Arrival times, scheduled departures	Total cost incl. delayed departure and decay	Evolutionary algorithm
Abtahi (2025)	Inbound/outbound/compound; separate receiving and shipping doors	No (full unloading)	Arrival times	Loaded quantity in a working period	MIP, SA
Nowak and Puladi (2025)	Compound; mixed-service doors, preemption	No (full unloading)	None (all start at time 0)	Makespan	GA, VNS
Li et al. (2026)	Inbound/outbound; mixed-mode docks	—	Time windows	Tardiness, makespan, AGV travel	Q-learning ALNS
This study	Compound + outbound	Yes	Release times + soft due dates	Makespan + $\lambda \times$ tardiness	MILP, CP-SAT, VAA-GILS

본 논문의 구성은 다음과 같다. 제 2 장에서 문제를 정의하며 혼합정수계획 모형과 CP-SAT 모형을 제시한다. 제 3 장에서 제안 알고리즘인 VAA-GILS 를 서술하고, 제 4 장과 제 5 장에서 실험 설계와 결과를 제시한다. 제 6 장에서 결과를 논의하고 제 7 장에서 결론을 맺는다.

2. 문제 정의

2.1 기호 정의

본 장의 정식화에 사용하는 기호를 집합, 파라미터, 결정변수로 나누어 아래 상자에 먼저 정리한다.

집합 (Sets)	
I	병행 트럭(compound truck)의 집합, $i, j \in I$

F	출고트럭(outbound truck)의 집합, $f, g \in F$
D	목적지의 집합, $d \in D$; 각 목적지에는 운송 트럭이 정확히 한 대 배정되므로 $ D = I + F $
K	상품 종류의 집합, $k \in K$
M	도어의 집합, $m, n \in M$; $ I \leq M $
$I \cup F$	전체 트럭의 집합, $q \in I \cup F$
파라미터 (Parameters)	
f_{idk}	병행 트럭 i 가 신고 온 목적지 d 행 상품 k 의 화물량
t_k	상품 k 의 단위 처리시간
t_{mn}	도어 m 과 n 사이의 배치 이송시간
DE_q, DL_q	트럭 q 의 도어 진입 전환시간과 출차 전환시간
h_{id}	병행 트럭 i 의 목적지 d 행 화물 처리시간, $h_{id} = \sum_{k \in K} f_{idk} t_k$
H_i	병행 트럭 i 의 전체 화물 처리시간, $H_i = \sum_{d \in D} h_{id}$
L_d	목적지 d 행 전체 화물의 적재시간, $L_d = \sum_{i \in I} h_{id}$
L_{id}	병행 트럭 i 가 목적지 d 를 유지할 때 다른 병행 트럭에서 옮겨 실을 화물의 적재시간, $L_{id} = \sum_{j \in I \setminus \{i\}} h_{jd}$
r_q	트럭 q 의 도착 시각(release time), 즉 도어 작업을 시작할 수 있는 가장 이른 시각, $r_q \geq 0$
$\bar{d}_q$	트럭 q 의 연성 납기(soft due date), 위반은 허용되나 납기지연으로 벌점을 받음
λ	납기지연 한 단위 시간에 부과하는 벌점 계수, $\lambda \geq 0$
B	big- M 제약에 쓰는 유효한 horizon 상한
결정변수 (Decision Variables)	
x_{idm}	병행 트럭 i 가 목적지 d 를 유지하고 도어 m 에 배정되면 1, 아니면 0
z_{fdm}	출고트럭 f 가 목적지 d 와 도어 m 에 배정되면 1, 아니면 0
b_{fgm}	도어 m 에서 출고트럭 f 가 g 보다 먼저 작업하면 1, 아니면 0
X_{im}, Z_{fm}, Z_{fd}	배정 보조 변수, $X_{im} = \sum_d x_{idm}$, $Z_{fm} = \sum_d z_{fdm}$, $Z_{fd} = \sum_m z_{fdm}$
U_i	병행 트럭 i 의 하역 완료 시각
C_i	병행 트럭 i 의 도어 작업 완료 시각
S_f	출고트럭 f 의 도어 작업 시작 시각(적재 시작은 $S_f + DE_f$)
C_f	출고트럭 f 의 완료 시각
$C_{\max}$	총 작업완료시간(makespan), $\tau = C_{\max}$
T_q	트럭 q 의 납기지연(tardiness), $T_q \geq \max\{0, C_q - \bar{d}_q\}$

2.2 기본 모델

이 문제의 결정은 세 가지이다. 각 병행 트럭이 유지할 목적지 하나와 배정될 도어 하나(도어당 병행 트럭은 최대 1 대), 각 출고트럭이 맡을 나머지 목적지 하나와 배정될 도어, 그리고 같은 도어에 배정된 출고트럭들의 작업 순서이다. 각 목적지에는 정확히 하나의 운송 트럭이 배정된다. 병행 트럭 i 의 도착 시각 r_i 는 하역을 시작할 수 있는 가장 이른 시각이고, 출고트럭 f 의 도착 시각 r_f 는 적재를 위한 도어 작업을 시작할 수 있는 가장 이른 시각이다. 연성 납기 $\bar{d}_q$ 와 납기지연 T_q 는 2.4 절의 목적식에서 사용한다.

각 트럭의 작업 시각은 다음과 같이 계산한다(<Figure 1>). 병행 트럭 i (목적지 d 유지)의 하역은 $r_i + DE_i + \sum_{d' \neq d} h_{id'}$ 에 끝난다. 운송 트럭은 화물을 보내는 모든 트럭의 하역과 도어 간 이송이 끝나야 적재할 수 있다. 출고 운송 트럭 f 는 추가로 자신의 도착 시각과 도어의 선행 점유가 끝나는 시점에 도어 작업을 시작하여 $S_f = \max(\text{door available, destination ready, } r_f)$ 이며, 이후 진입(DE_f), 적재, 출차(DL_f)를 차례로 수행하므로 완료 시각은 $S_f + DE_f + L_d + DL_f$ 이다. 즉 S_f 는 적재 시작이 아니라 도어 작업 시작 시각이고, 적재는 $S_f + DE_f$ 에 시작한다. 총 작업완료시간 $\tau = C_{\max}$ 는 최대 완료 시각이다.




Figure 1. Processing timelines for the two alternative carrier configurations: (a) a compound truck retaining destination d , and (b) a dedicated outbound truck assigned to destination d .

2.3 Mixed-integer 정식화

2.1 절의 결정변수를 사용하면 배정 제약은 다음과 같다.

$$\sum_{d,m} x_{idm} = 1 \quad \forall i \quad (1), \quad \sum_{d,m} z_{fdm} = 1 \quad \forall f \quad (2)$$

$$\sum_{i,m} x_{idm} + \sum_{f,m} z_{fdm} = 1 \quad \forall d \quad (3), \quad \sum_{i,d} x_{idm} \leq 1 \quad \forall m \quad (4)$$

병행 트럭의 작업 시각 관계와 화물 이송에 따른 선행 제약은 다음과 같다.

$$U_i = r_i + DE_i + H_i - \sum_{d,m} h_{id} x_{idm} \quad \forall i \quad (5)$$

$$C_i \geq U_i + L_{id} + DL_i - B(1 - x_{idm}) \quad \forall i, d, m \quad (6)$$

$$C_i \geq U_j + t_{nm} + L_{id} + DL_i - B(2 - x_{idm} - X_{jn}) \quad (7)$$

식 (7)은 모든 i, d, m, n 과, 해당 목적지 화물을 싣고 온($\sum_k f_{jdk} > 0$) 다른 병행 트럭 $j \neq i$ 에 대해 성립한다.

출고 운송 트럭에 대해서는 다음이 성립한다.

$$S_f \geq r_f \quad \forall f \quad (8)$$

$$C_f \geq S_f + DE_f + L_d + DL_f - B(1 - Z_{fd}) \quad \forall f, d \quad (9)$$

$$S_f \geq U_i + t_{nm} - B(2 - z_{fdm} - X_{in}) \quad (10)$$

식 (10)은 모든 f, d, m, n 과, 해당 목적지 화물을 싣고 온($\sum_k f_{idk} > 0$) 병행 트럭 i 에 대해 성립한다.

$$S_f \geq C_i - B(2 - Z_{fm} - X_{im}) \quad \forall f, i, m \quad (11)$$

같은 도어 m 을 쓰는 출고트럭 쌍 $f < g$ 에 대한 순서 결정과 non-overlap 제약은 다음과 같다.

$$b_{fgm} + b_{gfm} \geq Z_{fm} + Z_{gm} - 1, \quad b_{fgm} \leq Z_{fm}, \quad b_{gfm} \leq Z_{gm} \quad (12)$$

$$S_g \geq C_f - B(1 - b_{fgm}) \quad (13), \quad S_f \geq C_g - B(1 - b_{gfm}) \quad (14)$$

끝으로 총 작업완료시간은 다음으로 정의된다.

$$C_{\max} \geq C_i \quad \forall i, \quad C_{\max} \geq C_f \quad \forall f \quad (15)$$

CP-SAT 모형에서는 big- M 제약 대신 enforcement literal 을 사용하고, CP-SAT 가 정수만 다루므로 모든

시간값을 0.01 단위로 반올림한 뒤 100 배하여 정수로 바꾼다. 또한 두 모형에서 모든 배정을 고정하면

각 트럭의 완료 시각이 2.2 절의 계산 규칙을 독립적으로 구현한 스케줄 평가기의 결과와 일치하여, 모형이 문제 정의를 정확히 반영함을 확인하였다.

2.4 시간 제약 확장과 목적식

각 트럭 $q \in I \cup F$ 의 납기지연은 $T_q \geq \max\{0, C_q - \bar{d}_q\}$ 이다. 목적식은

$$\min J = C_{\max} + \lambda \sum_{q \in I \cup F} T_q, \quad \lambda = 1 \quad (16)$$

λ 는 납기지연 한 단위 시간에 부과하는 벌점 계수(penalty coefficient)로, 총 작업완료시간과 납기 준수 사이의 관리적 선호를 반영하는 파라미터이다(5.4 절). $r_q = 0$, $\bar{d}_q = \infty$ 이면 기존 총 작업완료시간 모델로 환원된다. CP-SAT 는 제한시간 안에 찾은 현재 최선해(incumbent)의 목적값과 증명된 하한을 함께 반환하며, 본 논문에서는 두 값이 일치하여 최적성이 증명된 경우에만 최적해라고 부른다.

3. 휴리스틱 알고리즘

VAA-GILS 는 반복 지역탐색(iterated local search; Lourenço 등, 2019)의 구현체로, 연산자 선택(operator selection), 연산자 내부 표본추출(sampling), 섭동(kick)을 제외하면 결정론적이다. 이하에서 **원 모델**은 Shahmardan 과 Sajadieh(2020)가 제안한 SA-RL5 를 가리키며, VAA 구성 휴리스틱과 기본 이웃 7 종은 이 모델에서 가져왔다.

초기해 구성(initial solution construction). 원 모델의 VAA 는 Vogel 식 후회도(regret)로 병행 트럭의 유지 목적지를 정하고, 완료 시각 우선순위에 따라 출고 목적지를 배정한다. 도어 배정은 먼저 처리되는

트럭을 도어 간 이송시간 합이 가장 작은 중앙 도어에 두고, 나머지 트럭은 작업 종료가 가장 이른 도어에 차례로 삽입한다. 모든 완료 예정 시각 계산에는 도착 시각을 반영한다.

하강 탐색(descend search). 세 가지 이동 유형(출고트럭의 도어와 작업 순서 재배치, 병행 트럭의 도어 교환/빈 도어 이동, 두 트럭의 목적지 교환)에 대한 최선개선 지역탐색(best-improvement local search)으로, 지역 최적해(local optimum)에서 종료하며 초기해와 새로 갱신된 현재 최선해, 최종해에 적용한다.

반복 탐색(iterated search). 1,000 회 반복한다. 선택 정책이 연산자 하나를 뽑아 현재 해에서 후보를 생성하고, 후보가 전역 최선해를 개선하면 하강 탐색을 적용해 현재 최선해를 갱신한다. 수락 규칙(acceptance rule)은 후보가 현재 해를 엄격히 개선할 때만 받아들이는 탐욕적(greedy) 규칙이다. 조정 집합에서 이 규칙을 모의 담금질(simulated annealing; Kirkpatrick 등, 1983) 수락 규칙과 비교하였다. SA 규칙은 초기 온도 $T_0 = \max\{1, 0.05 J(s_0)\}$, 기하 냉각 $T \leftarrow 0.995 T$, 재시작 시 재가열(reheating)을 사용한다. 45 개 인스턴스 중 36 개에서 탐욕적 규칙이 더 좋은 해를 찾아(양측 Wilcoxon $p = 0.0007$) 이를 채택하였고, 시험 집합에서도 SA 수락 규칙을 추가하면 해가 유의하게 나빠졌다(<Table 7>).

섭동 재시작(kick restart). 30 회 연속 개선이 없으면 섭동 재시작을 수행한다. 현재 최선해 s^* 의 복사본에서 다시 시작하되, 아래 기본 이웃 7 종에서 균등 무작위로 뽑은 섭동 이동(kick)을 3 회 연속 적용한다. 각 이동은 직전 이동의 결과에 적용되며, 재시작 직후에는 하강 탐색을 수행하지 않는다.

연산자 집합(operator pool). 기본 이웃 7 종은 원 모델의 이웃 구조를 그대로 사용한다: (k1) 두 트럭의 목적지 교환, (k2) 병행 트럭 간 도어 교환, (k3) 출고트럭 간 도어 교환, (k4) 출고트럭을 다른 도어로 삽입, (k6) 하역시간 기반 룰렛 선택(roulette-wheel selection)으로 병행 트럭을 도어에 삽입, (k7) 적재시간 기반 룰렛 선택으로 출고트럭을 도어에 삽입, (k8) 룰렛 선택으로 병행 트럭에 목적지를 배정. 원 모델은 이동을 k1-k8 로 번호매기나 k5 는 정의하지 않아 실제 구현은 7 종이다. 여기에 현재 병목을 먼저 식별한 뒤 그 주변에서 가능한 후보를 모두 평가해 최선을 택하는 유도 연산자(guided operator) 4 종을 더한다: (g1) 병목 도어(critical door)의 마지막 출고트럭을 최선 도어와 위치로 재배치, (g2) 병목 트럭의 목적지를 전 트럭과 대조해 최선 교환, (g3)/(g4) 납기지연이 가장 큰 트럭 기준의 동일 이동(납기지연이 있는 트럭이 없으면 g1/g2 로 대체). 고속 증분 평가기(fast incremental evaluator)는 해 하나를 평가하는 데 시험 인스턴스 기준 S 에서 약 25-28 마이크로초(μ s), L 에서 약 95-148 마이크로초가 걸려 하강 탐색과 유도 연산자를 저렴하게 만든다.

선택 정책(selection policy)과 원 모델의 비교. 선택 정책은 교체할 수 있으며 기본값은 균등 무작위 선택이다. 학습 정책(SA-RL5 의 tabular Q-learning(Watkins and Dayan, 1992), 규모 불변 특징(scale-invariant feature)으로 오프라인 학습한 transfer DQN(Mnih 등, 2015))은 ablation 목적으로만 평가하며 제안 방법의 일부가 아니다. tabular Q 는 원 모델과 같이 무개선 구간 5-상태에서 일정 확률로는 연산자를 무작위로 고르고(ϵ -greedy 탐험) 나머지는 Q 값이 큰 연산자를 우선 고른다(룰렛 활용). 다만 보상은 다르게 준다. 원 모델은 후보가 현재 해보다 나쁘지 않으면 1, 그렇지 않으면 0 을 주지만, 본 연구는 현재 최선해를 갱신하면 2, 나빠지지 않으면 1, 그 외에는 0 을 주는 셰이핑 보상(shaped

reward)을 쓴다. 이는 학습 신호를 강화할 뿐이므로 비교 대상 선택 정책을 불리하게 만들지 않는다. 원 모델 SA-RL5 는 RL 이 단일 이동을 고르고 SA 수락 또는 거절로 한 단계가 끝나는 순수 모의 담금질인 반면, VAA-GILS 는 그 한 연산자 적용 단계를 반복 지역탐색 안에 넣고 유도 연산자, 개선 이동마다의 하강 탐색, 섭동 재시작을 더하며, 확률적 수락 규칙 대신 탐욕적 수락 규칙을 쓴다. ablation(5.2 절)은 이 가운데 섭동 재시작의 기여가 가장 크고 유도 연산자와 하강 탐색이 그 뒤를 이음을 보인다. 두 방법의 구조적 차이는 <Table 2>에 정리하였다.

Table 2. Structural comparison of the base SA-RL5 and VAA-GILS.

Aspect	SA-RL5 (base)	VAA-GILS (proposed)
Overall framework	Pure simulated annealing	Iterated local search
Operators per iteration	One	One (same)
Operator set	7 generic neighborhoods	Those 7 + 4 guided
Operator selection	Online Q-learning / roulette	Uniform random (learning only in ablation)
After an improving move	None (the SA step is the whole iteration)	Full best-improvement descent
Stagnation handling	None	Kick restart
Acceptance	SA (Metropolis)	Greedy (improving candidates only)
Objective	Makespan	Makespan + $\lambda \times$ total tardiness

4. 실험 설계

4.1 인스턴스 생성

병행 트럭 $|I|$, 출고트럭 $|F|$, 목적지 $|D| = |I| + |F|$, 도어 $|M| = |I|$ 로 두고 세 규모를 사용한다: S

$(|I|, |F|) = (6, 3)$, M $(12, 6)$, L $(20, 10)$. 따라서 $(|I|, |D|, |M|)$ 은 각각 $(6, 9, 6)$, $(12, 18, 12)$, $(20, 30, 20)$ 이고 병행

트럭 비율 $|I|/|D|$ 는 모두 2/3이다. S 는 CP-SAT 가 일부 조건에서 제한시간 안에 최적성을 증명할 수

있는 소규모 문제이며, L 은 제한시간 안에 실행 가능해 확보도 어려운 대규모 문제여서 두 극단을 함께

본다. 병행 트럭 비율을 높게 잡은 것은, 이 비율이 낮으면 문제가 일반 크로스도킹 스케줄링에 가까워져
부분 하역 구조의 영향이 드러나지 않기 때문이다.

나머지 생성 파라미터는 <Table 3>에 정리하였다. 화물이 특정 목적지로 쏠리는 정도는 이와 별개의
조건이며, 보고하는 모든 실험은 쏠림이 없는 조건을 사용한다(소수 목적지에 물량이 물리는 쏠린 조건과
병행 트럭별 권역이 나뉘는 군집 조건은 transfer DQN 학습에만 쓴다). 도어를 일렬로 늘어놓으면
이송시간이 도어 번호 차이로 정해져 도어 배정이 해에 미치는 영향이 작아지므로, 배정 결정이 실제로
품질을 가르도록 무작위 배치를 쓴다. 이송 거리를 10 으로 나누는 것은 이송시간을 처리시간과 같은
크기 범위에 두기 위해서다.

Table 3. Instance generation parameters. Flow, handling and enter/leave times are drawn from integer uniform distributions.

Item	Symbol	Value
Size (compound/outbound/des tination/door)	(I , F , D , M)	S (6,3,9,6); M (12,6,18,12); L (20,10,30,20)
Compound-truck ratio	$ I / D $	2/3
Number of product types	$ K $	3
Flow	f_{iak}	$U[0,20]$
Unit handling time	t_k	$U[1,4]$
Enter/leave time	DE_q, DL_q	$U[1,5]$
Door coordinates	—	uniform on $[0,100]^2$
Inter-door travel time	t_{mn}	Euclidean distance / 10
Release time	r_q	none: 0; otherwise $U[0, \rho H]$
Soft due date	$\bar{d}_q$	none: ∞ ; otherwise $r_q + \delta H$
Time-constraint level	(ρ, δ)	medium (0.25,0.60); tight (0.50,0.35)

4.2 시간 제약 수준

시간 제약은 none, medium, tight 세 수준이다. none 은 $r_q = 0$, $\bar{d}_q = \infty$ 로 두어 모든 트럭이 시각 0 에 가용하고 납기가 없는 원 모델과 같으며, 본 연구의 확장을 꺾을 때의 대조군 역할을 한다. medium 과 tight 에서는 $r_q \sim U[0, \rho H]$, $\bar{d}_q = r_q + \delta H$, $(\rho, \delta) = (0.25, 0.60), (0.50, 0.35)$ 이다. 여기서 $H = 2 \sum_{i \in I} H_i / |M|$ 은 시간 제약이 없을 때의 총 작업완료시간 추정치로, 화물 한 단위가 하역과 적재로 두 번 처리되므로 계수 2 를 둔다. 시간 제약을 H 의 비율로 주면 규모가 달라져도 압박 수준이 유지된다. ρ 는 도착이 퍼지는 폭, δ 는 도착 후 납기까지의 여유를 뜻하므로, tight 는 두 방향으로 동시에 어려워지는 조건이다.

규모 3 종과 시간 제약 3 수준을 교차해 총 9 개의 실험 조건을 만들고, 각 조건을 S-none, M-tight 와 같이 규모-수준 형태로 표기한다.

4.3 비교 대상과 측정

비교 대상은 여섯이다. (i) VAA 는 구성 휴리스틱만 적용한 초기해, (ii) Paper-SA-RL5 는 원 모델의 재구현, (iii) Extended SA-RL5 는 Paper-SA-RL5 의 해 표현과 이웃 구조, Q-learning 연산자 선택, SA 수락 규칙을 그대로 두고 평가기와 목적식만 식 (16)으로 확장한 것이며, (iv)–(vi) GILS-uniform, GILS-tabular, GILS-DQN 은 선택 정책만 바꾼 제안 방법의 세 변형이다. 제안 방법의 기본값은 GILS-uniform 이고 나머지 두 변형은 학습 기반 선택의 효과를 보기 위한 것이다. 여기에 CP-SAT 결과를 함께 보고한다. 원 모델은 도착 시각과 납기를 다루지 않으므로 Paper-SA-RL5 는 none 조건에서, Extended SA-RL5 는 medium 과 tight 조건에서 비교한다. none 조건에서는 납기 지연 항이 사라져 Extended SA-RL5 가 Paper-SA-RL5 와 같아진다.

인스턴스 seed 는 학습과 조정, 시험 세 집합으로 서로소가 되게 나눈다. 학습 정책은 학습 집합에서만 훈련하고 λ 와 수락 규칙 같은 설계 값은 조정 집합에서만 고르므로 시험 집합의 성능이 부풀려지지 않는다. 주 해품질 비교(<Table 4>)는 조건당 시험 인스턴스 20 개를 각각 5 회 반복 실행한다. 인스턴스마다 난이도가 다르므로 여러 개가 필요하고, 알고리즘에 무작위성이 있으므로 같은 인스턴스도 여러 번 실행한다. 통제된 ablation(<Table 6>, <Table 7>)은 같은 엔진에서 구성요소만 떼어내는 짝지은 비교여서 인스턴스 간 난이도 편차가 상쇄되므로 조건당 5 개만 사용하고, 선택 정책 비교(<Table 8>)는 주 비교와 같은 조건당 20 개 인스턴스를 사용한다.

같은 인스턴스의 5 회 반복은 서로 독립이 아니므로, 먼저 인스턴스별로 평균해 조건당 값 하나를 만든 뒤 짝지은 인스턴스 평균에 양측 Wilcoxon signed-rank test 를 적용한다. 따라서 짝의 수 n 은 비교에 포함된 인스턴스 수를 넘지 않으며, 두 방법의 평균이 같아 차이가 0 인 짝은 검정에서 제외된다.

본 논문은 해를 비교하는 기준을 세 가지로 엄격히 구분한다. **최적해**(optimal solution)는 CP-SAT 가 반환한 해의 목적값이 증명된 하한과 일치하여 최적성이 증명된 해이다. **기준해**(reference solution)는 CP-SAT 가 제한시간 안에 반환한 현재 최선해로, 최적성이 증명되지 않은 해를 포함하며 "최적"으로 부르지 않는다. **관측 최선해**(best observed solution)는 한 인스턴스에 대해 모든 방법, 모든 반복 횟수, CP-SAT 결과를 통틀어 관측된 가장 좋은 해로, 최적성에 대한 보장이 없다. 주 지표는 인스턴스별 격차 Δ_{bo} 이며, 해당 인스턴스에 대해 모든 방법과 모든 반복 횟수, CP-SAT 결과까지 통틀어 관측된 가장 좋은 목적값을 기준으로 삼는다. 대형 조건에서는 CP-SAT 기준해가 없어 최적해 대비 갭을 쓸 수 없기 때문이다.

Paper-SA-RL5 와 Extended SA-RL5 를 포함한 모든 메타휴리스틱의 종료 조건은 반복 횟수 1,000 회로 통일한다. 한 반복은 선택된 연산자 하나로 후보해를 생성하고 평가하는 단계이며, GILS 는 여기에 개선 시 하강 탐색을 더 수행한다. 원 모델은 CPU 시간으로 종료하지만 본 연구는 모든 방법에 같은 반복 횟수를 부여하였고, 반복당 계산량이 방법마다 다르므로 실행 시간은 <Table 4>에 함께 보고한다. CP-SAT 는 인스턴스당 1 회, 8 thread 로 S 에 300 초(조건당 20 개), M 과 L 에 600 초(조건당 2 개)를 부여하며, 최적성은 S-none 20 개 전부와 S-medium 1 개에서 증명된다. 보고하는 CP-SAT 계산 시간은 모형 구성과 solver 종료 처리를 포함한 wall-clock 시간이므로 명목 제한시간(600 초)을 약간 넘을 수 있다. 실험은 Apple M2 칩(8 코어)과 16 GB 메모리를 갖춘 macOS 환경에서 Python 3.12 와 OR-Tools 9.15 로 수행하였다.

5. 실험 결과

5.1 해 품질

<Table 4>에 20 개 인스턴스에 대한 시험 결과를 요약한다. CP-SAT 가 기준해를 제공한 실험 조건에서 GILS 는 이에 근접하며, 기본 선택 정책인 균등 선택 기준으로 그 격차는 평균 0.10–0.23%이다(학습 선택 정책을 포함한 전체 변형은 0.08–0.48%, 5.3 절). 최적성이 증명된 S-none 20 개 인스턴스에서 균등 선택 GILS 는 최적해보다 평균 0.23% 높다. 같은 선택 정책 기준으로 VAA 대비 격차는 평균 2.66%($n = 180$, $p < 0.0001$), SA-RL5 대비 격차는 1.44%($n = 60$, $p < 0.0001$)이다. medium 과 tight 조건에서 Extended SA-RL5 대비 격차는 평균 0.93%($n = 120$, $p < 0.0001$)이다. 실행 시간은 S/M/L 에서 각각 0.09, 0.49, 2.43 초이다. CP-SAT 가 기준해를 반환한 조건에서 CP-SAT 의 평균 계산 시간은 S-none 40 초, S-

medium 245 초, S-tight 250 초, M-none 606 초로 같은 조건의 GILS(각각 0.09, 0.09, 0.09, 0.47 초)보다 100 배 이상 길며, M 의 시간 제약 조건과 L 의 모든 조건에서는 CP-SAT 가 제한시간 안에 실행 가능해를 반환하지 못했다.

GILS 는 개선 이동 뒤 하강 탐색을 추가로 수행하므로 같은 반복 횟수가 같은 계산량을 뜻하지는 않는다.

이를 통제하기 위해, 각 시험 실행(조건, 인스턴스, 반복)에서 GILS 가 실제로 사용한 실행 시간을 같은 실행의 SA-RL5(시간 제약 조건은 Extended SA-RL5)에 그대로 부여하고 시간이 다할 때까지 반복하게 한 동일 wall-clock 비교를 추가로 수행하였다(<Table 5>). L 에서는 SA-RL5 가 평균 1,491 회로 반복 1,000 회 비교보다 약 1.5 배의 탐색을 수행하지만(S 에서는 GILS 가 더 빨라 558 회), GILS 는 모든 규모에서 동일 시간의 SA-RL5 보다 좋은 해를 찾았고(전체 평균 1.30%, $p < 0.0001$) SA-RL5 가 앞선 인스턴스는 180 개 중 하나도 없었다. 따라서 GILS 의 성능 향상은 추가 계산량이 아니라 탐색 구조에서 비롯된다.

Table 4. Test results over 20 instances per experimental condition (20 instances $\times$ 5 replications). Δ_{bo} is the mean gap to the best observed solution and time is the mean per run. The vs CP-SAT column is computed only on the subset for which CP-SAT returned a reference (20 instances per S condition, 2 for M-none); optimality was proven for all 20 S-none instances and one S-medium instance. On that subset the mean CP-SAT runtime is 178 s (S) and 606 s (M-none).

Condition	Method	Mean obj. $\pm$ s.d.	$\Delta_{bo}(\%)$	vs CP-SAT(%)	Time(s)
S-none	VAA	1497.5 $\pm$ 400.3	6.61	+6.61	0.00
	Paper-SA-RL5	1423.8 $\pm$ 383.8	1.07	+1.07	0.16
	GILS-uniform	1412.4 $\pm$ 382.0	0.23	+0.23	0.09
S-medium	VAA	5447.5 $\pm$ 1468.9	3.90	+3.90	0.00
	Extended-SA-RL5	5302.0 $\pm$ 1431.8	0.97	+0.97	0.17
	GILS-uniform	5259.4 $\pm$ 1412.1	0.17	+0.17	0.09
S-tight	VAA	9276.8 $\pm$ 2387.6	2.91	+2.91	0.00
	Extended-SA-RL5	9056.3 $\pm$ 2214.9	0.61	+0.61	0.16
	GILS-uniform	9011.9 $\pm$ 2206.5	0.11	+0.11	0.09
M-none	VAA	3030.9 $\pm$ 903.6	3.72	+4.80	0.00
	Paper-SA-RL5	2979.2 $\pm$ 860.9	1.98	+1.55	0.60
	GILS-uniform	2929.5 $\pm$ 844.2	0.28	+0.10	0.47
M-medium	VAA	23025.5 $\pm$ 4075.4	2.58	—	0.00
	Extended-SA-RL5	22821.9 $\pm$ 3985.3	1.65	—	0.54
	GILS-uniform	22513.0 $\pm$ 3960.7	0.25	—	0.50
M-tight	VAA	38903.7 $\pm$ 11283.5	1.26	—	0.01
	Extended-SA-RL5	38811.1 $\pm$ 11075.1	0.99	—	0.52
	GILS-uniform	38501.1 $\pm$ 11067.3	0.13	—	0.52
L-none	VAA	5492.3 $\pm$ 1482.2	2.17	—	0.02
	Paper-SA-RL5	5480.3 $\pm$ 1450.5	1.94	—	1.95
	GILS-uniform	5383.9 $\pm$ 1423.8	0.15	—	2.37
L-medium	VAA	55611.1 $\pm$ 18087.3	1.57	—	0.02
	Extended-SA-RL5	55544.0 $\pm$ 17684.8	1.46	—	1.49
	GILS-uniform	54825.9 $\pm$ 17531.9	0.11	—	2.47
L-tight	VAA	119671.9 $\pm$ 32475.3	0.78	—	0.02
	Extended-SA-RL5	119634.3 $\pm$ 31842.5	0.74	—	1.57
	GILS-uniform	118863.6 $\pm$ 31785.2	0.06	—	2.45

Table 5. Budget-fairness check (20 instances $\times$ 5 replications per condition). SA-RL5 denotes Paper-SA-RL5 on none and Extended SA-RL5 on medium/tight. Gain is the mean relative objective difference in favor of GILS-uniform; SA-RL5 wins counts instances where the time-matched SA-RL5 has the better replication mean. Two-sided Wilcoxon on per-instance replication means, $p < 0.0001$ in every row.

Size	n	GILS	SA-RL5 iterations	Gain vs 1,000 it.(%)	Gain vs same	SA-RL5 wins
		time(s)	(same time)		time(%)	
S	60	0.09	558	+0.71	+1.45	0
M	60	0.49	935	+1.32	+1.45	0
L	60	2.43	1,491	+1.27	+1.01	0
All	180	1.01	994	+1.10	+1.30	0

5.2 핵심 구성요소 분석: 성능은 어디에서 오는가

세 가지 통제된 ablation(반복 횟수 1,000 회 고정)으로 엔진을 분해한다.

연산자 집합. 선택 정책을 균등 선택으로 고정하고 연산자 집합만

기본(7 종)/핵심(+g1,g2)/전체(+g3,g4)로 바꾸면, 기본에서 핵심으로 갈 때 Δ_{bo} 가 9 개 실험 조건

전부에서 낮아지고(<Figure 2>) 짝지은 Wilcoxon(<Table 6>)에서도 g1, g2 추가의 효과가 뚜렷하다($p <$

0.0001). 반면 g3, g4 를 더한 효과는 +0.034%p 로 작고($p = 0.013$), 시간 제약 유무로 나누면 유의하지

않아($p = 0.051, 0.12$) 보조적인 효과로 본다. L-tight 에서는 오히려 전체 집합의 Δ_{bo} 가 0.01%p 높다.

따라서 유도 연산자의 이득은 대부분 g1, g2 에서 나온다.

Table 6. Operator-pool ablation (5 instances $\times$ 5 replications per condition over 9 conditions, the number of iterations fixed at 1,000; two-sided Wilcoxon on per-instance replication means, hence at most 45 pairs, with zero differences excluded from n ; positive mean favors the richer operator set).

Contrast	n	Gain(%p)	p
generic $\rightarrow$ critical (add g1, g2)	45	+0.150	<0.0001
critical $\rightarrow$ full (add g3, g4)	45	+0.034	0.0130
generic $\rightarrow$ full (all guided)	45	+0.184	<0.0001




Figure 2. Mean gap to the best observed solution by operator set.

엔진 구성요소. <Table 7>은 연산자 집합을 전체로, 선택 정책을 균등 선택으로 고정한 최종 엔진에서 구성요소를 하나씩 제거하거나 SA 수락 규칙과 reheating 을 추가했을 때의 결과이다. 섭동 재시작을 제거했을 때 해가 가장 크게 나빠졌으며, 이 악화는 시간 제약 유무와 관계없이 유의하다. 하강 탐색 제거의 악화(+0.064%p, $p = 0.002$)는 유의하지만 재시작 제거의 약 1/6 수준이다. 무작위 초기해의 악화(+0.057%p, $p = 0.049$)는 경계 수준이고 시간 제약 유무로 나누면 유의하지 않으므로, VAA 초기해의 기여는 작고 보조적이다. SA 수락 규칙과 reheating 을 추가하면 목적값이 오히려 나빠져, 조정 집합에서 정한 greedy 수락 규칙을 시험 집합에서도 뒷받침한다.

Table 7. Engine-component ablation (5 instances $\times$ 5 replications per condition over 9 conditions; one change at a time to the final greedy-acceptance engine, relative objective degradation after the change; two-sided Wilcoxon on per-instance replication means, hence at most 45 pairs, with zero differences excluded from n).

Change to the final engine	n	Degradation(%p)	p
remove best-improvement descent	45	+0.064	0.0016

Change to the final engine	n	Degradation(%p)	p
remove kick restart	45	+0.375	<0.0001
random start instead of VAA	45	+0.057	0.0495
add SA acceptance + reheating	45	+0.036	0.0043

5.3 보조 분석: 학습 기반 연산자 선택

연산자 집합과 구성요소를 전체로 고정하고 선택 정책만 바꾸면(<Table 8>), 어떤 학습 정책도 균등 선택보다 좋지 않다. tabular Q-learning 은 균등 선택보다 평균 0.040%p, transfer DQN 은 0.093%p 나쁘며 둘 다 유의하다. 반복 횟수를 50–3,000 회로 바꾸어도 모든 반복 횟수에서 균등 선택의 격차가 가장 작고, 3,000 회에서만 tabular 가 균등 선택에 근접한다(0.13% 대 0.12%). 이러한 결과는 무제약 조건만으로도 성립하므로(균등 선택 대비 tabular $-0.040\%p$, DQN $-0.124\%p$, 모두 $p < 0.0001$) 시간 제약 확장 때문에 나타난 결과가 아니다.

Table 8. Effect of the selection policy (20 instances $\times$ 5 replications per condition over 9 conditions, 1,000 iterations; two-sided Wilcoxon on per-instance replication means, hence at most 180 pairs, with zero differences excluded from n ; positive mean favors the first method).

Comparison	n	Mean diff.(%p)	p	Verdict
tabular vs uniform	179	-0.040	<0.0001	Tabular worse
tabular vs DQN	179	$+0.053$	<0.0001	DQN worse
uniform vs DQN	179	$+0.093$	<0.0001	DQN worse

5.4 납기지연 가중치 민감도

식 (16)은 총 작업완료시간과 총 납기지연이라는, 척도가 서로 다른 두 시간 성분을 합치므로, 조정 집합에서 $\lambda \in \{0, 0.25, 0.5, 1, 2, 4, 8\}$ 값을 바꿔가며 탐색한다. 물리적 총 작업완료시간과 총 납기지연을 인스턴스별로 min-max 정규화해 평균한다(<Figure 3>). 납기지연 감소의 대부분은 $\lambda = 0$ 에서 1 사이에서 일어나고 이후에는 그 폭이 줄어든다. 전체 탐색 구간에서 규모별 평균 총 작업완료시간은 0.6–

1.2% 상승하고 평균 납기 지연은 0.9–3.0% 하락한다. $\lambda = 1$ 을 채택한다: 완만한 총 작업완료시간 비용으로 납기 지연이 거의 최소에 이르며, 총 작업완료시간과 납기 지연에 단위 시간당 동일한 별점 계수를 부여한다. 다만 $c_{\max}$ 는 단일 최댓값이고 $\sum_q T_q$ 는 여러 트럭의 합이므로 계수가 같다고 두 성분이 목적식에 미치는 실질적 영향까지 같은 것은 아니다. λ 는 운영자가 총 작업완료시간 대비 납기 준수를 얼마나 중시하는지를 나타내는 관리적 선호(managerial preference) 파라미터이며, 실제 적용에서는 운영 여건에 맞게 조정할 수 있다. 이 분석은 시험 성능 평가가 아니라, 조정 인스턴스를 이용해 해당 설계 선택의 타당성을 검증하기 위한 것이다.




Figure 3. Normalized makespan-tardiness trade-off on tuning instances.

6. 논의

학습 기반 선택 정책이 균등 선택 대비 이득을 주지 못한 것은 학습 일반에 대한 결론이 아니라 본 논문의 탐색 구조가 낳은 결과다. 후보 하나의 평가에 수십-백수십 마이크로초(μs)밖에 들지 않아 연산자를 잘 고르는 것보다 많이 시도하는 편이 유리하고, 모든 신규 최선해 뒤에 결정론적 하강 탐색이

따라붙어 어떤 연산자로 그 지점에 이르렀는지의 차이를 상당 부분 흡수한다. 반복 횟수별 격차 곡선도 1,000 회 이후의 추가 개선이 작음을 보인다(조건당 5 개 인스턴스에서 균등 선택의 격차는 1,000 회 0.21%, 3,000 회 0.12%이고, 45 개 인스턴스 중 31 개에서 개선 폭이 0.1%p 미만이다. 1,000 회 값이 <Table 4>의 조건 평균 0.17%보다 큰 것은 기준 인스턴스가 조건당 20 개 중 5 개로 달라서이다). 정제 탈출은 섭동 재시작이 많으므로 SA 수락 규칙과 reheating 의 역할은 이와 겹치며, 조정 집합 비교와 시험 집합 ablation 에서 이 둘이 해 품질을 높이지 않아 최종 VAA-GILS 에서 제외하였다(3 장, <Table 7>). 즉 본 문제에서 성능 향상은 주로 섭동 재시작, 유도 연산자, 결정론적 하강 탐색에서 비롯되며, 학습된 선택 정책과 확률적 수락 규칙의 추가적인 기여는 제한적이다.

선택 정책이 예측할 대상이 마땅치 않다는 점도 작용한다. 본 문제의 인스턴스는 정적이고 모든 도착 시각이 최적화 이전에 알려져 있어, 실행 도중 새로 드러나 정책이 활용할 정보가 없다. 도착 정보가 시간에 따라 공개되는 동적 도크 운영이나 이동 하나의 평가가 비싼 시뮬레이션 기반 모형에서는 판단이 달라질 수 있다. 따라서 본 결과의 함의는 학습이 무용하다는 것이 아니라 비교 조건에 있다. 학습 기반 선택 정책은 같은 엔진, 같은 반복 횟수 아래에서 균등 선택과 견주어야 하며, 그 통제가 없으면 하강 탐색과 재시작, 강한 연산자 집합의 이득이 정책의 성과로 잘못 귀속될 수 있다.

7. 결 론

본 연구는 부분 하역된 병행 트럭이 출고 운송 트럭으로 전환된 뒤 다른 트럭에서 오는 이송 화물을 기다려야 하고, 이 대기가 트럭별 도착 시각 및 연성 납기와 결합하면서 지연이 공유 목적지를 따라 전파되는 구조를, 저자가 아는 한 처음으로 MILP 와 CP-SAT 모형으로 정식화하였다. CP-SAT 기준해가

있는 실험 조건에서 VAA-GILS의 목적값은 해당 기준해 대비 평균 0.10–0.23%였고(소형 무제약 조건의 20개 인스턴스는 CP-SAT가 모두 최적성을 증명하였으며 최적해 대비 평균 격차는 0.23%였다), CP-SAT가 600초 안에 실행 가능해를 찾지 못한 대형 시간 제약 조건에서도 약 2.5초 안에 VAA와 Extended SA-RL5보다 좋은 해를 제공하였다. 동일 wall-clock 예산에서도 VAA-GILS는 SA-RL5보다 일관되게 우수하여, 성능 향상이 추가 계산량이 아니라 탐색 구조에서 비롯됨을 확인하였다. ablation은 성능이 섭동 재시작, 유도 연산자, 하강 탐색이라는 결정론적 구조에서 비롯되며, 학습 기반 연산자 선택과 확률적 수락 규칙은 이 환경에서 실용적 이득을 주지 않아 최종 알고리즘은 greedy 수락 규칙을 사용한다. 향후에는 도착 정보가 실시간으로 공개되는 동적 문제, 대형 시간 제약 조건에서 해 품질을 평가할 수 있는 강한 하한 기법, 산업 데이터를 활용한 사례 연구가 필요하다.

생성형 AI 활용 내역

본 논문의 연구 및 작성 과정에서 저자는 OpenAI Codex(GPT-5, OpenAI)와 Claude Code(Anthropic)를 코드 작성 및 디버깅 보조와 논문의 문장 표현 및 가독성 개선을 위해 활용하였다. 생성형 AI의 도움을 받은 내용은 저자가 검토 및 수정하였으며, 논문의 모든 내용과 결과에 대한 책임은 저자에게 있다.

참고문헌

Abtahi, Z.(2025), Scheduling Compound Trucks with Various Arrival Times in a Multi-Door Cross-Docking System, *Supply Chain and Operations Decision Making*, 2(1), 21-30.

Assadi, M. T. and Bagheri, M.(2016), Differential Evolution and Population-Based Simulated Annealing for Truck Scheduling Problem in Multiple Door Cross-Docking Systems, *Computers & Industrial Engineering*, 96, 149-161.

Bodnar, P., de Koster, R., and Azadeh, K.(2017), Scheduling Trucks in a Cross-Dock with Mixed Service Mode Dock Doors, *Transportation Science*, 51(1), 112-131.

Boysen, N. and Fliedner, M.(2010), Cross Dock Scheduling: Classification, Literature Review and Research Agenda, *Omega*, 38(6), 413-422.

Joo, C. M. and Kim, B. S.(2013), Scheduling Compound Trucks in Multi-Door Cross-Docking Terminals, *International Journal of Advanced Manufacturing Technology*, 64, 977-988.

Karimi-Mamaghan, M., Mohammadi, M., Pasdeloup, B., and Meyer, P.(2023), Learning to Select Operators in Meta-Heuristics: An Integration of Q-Learning into the Iterated Greedy Algorithm for the Permutation Flowshop Scheduling Problem, *European Journal of Operational Research*, 304(3), 1296-1330.

Kirkpatrick, S., Gelatt, C. D., and Vecchi, M. P.(1983), Optimization by Simulated Annealing, *Science*, 220(4598), 671-680.

Konur, D. and Golias, M. M.(2013a), Analysis of Different Approaches to Cross-Dock Truck Scheduling with Truck Arrival Time Uncertainty, *Computers & Industrial Engineering*, 65(4), 663-672.

Konur, D. and Golias, M. M.(2013b), Cost-Stable Truck Scheduling at a Cross-Dock Facility with Unknown Truck Arrivals: A Meta-Heuristic Approach, *Transportation Research Part E*, 49(1), 71-91.

Ladier, A.-L. and Alpan, G.(2016), Robust Cross-Dock Scheduling with Time Windows, *Computers & Industrial Engineering*, 99, 16-28.

Larbi, R., Alpan, G., Baptiste, P., and Penz, B.(2011), Scheduling Cross Docking Operations under Full, Partial and No Information on Inbound Arrivals, *Computers & Operations Research*, 38(6), 889-900.

Li, M., Hao, J.-K., and Wu, Q.(2024), A Flow Based Formulation and a Reinforcement Learning Based Strategic Oscillation for Cross-Dock Door Assignment, *European Journal of Operational Research*, 312(2), 473-492.

Li, Y., Mohammadi, M., Zhang, X., Lan, Y., and van Jaarsveld, W.(2026), Integrated Trucks Assignment and Scheduling Problem with Mixed Service Mode Docks, *European Journal of Operational Research*, 333(1), 117-137.

Lourenço, H. R., Martin, O. C., and Stützle, T.(2019), Iterated Local Search: Framework and Applications, In Gendreau, M. and Potvin, J.-Y.(Eds.), *Handbook of Metaheuristics*, Springer, Cham, 129-168.

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran,

D., Wierstra, D., Legg, S., and Hassabis, D.(2015), Human-Level Control through Deep Reinforcement Learning, *Nature*, 518, 529-533.

Molavi, D., Shahmardan, A., and Sajadieh, M. S.(2018), Truck Scheduling in a Cross Docking Systems with Fixed Due Dates and Shipment Sorting, *Computers & Industrial Engineering*, 117, 29-40.

Nowak, M. and Puladi, S.(2025), Value of Operational Flexibility in Cross-Docking, *Computers & Industrial Engineering*, 209, 111423.

Ozden, G. and Saricicek, I.(2019), Scheduling Trucks in a Multi-Door Cross-Docking System with Time Windows, *Bulletin of the Polish Academy of Sciences: Technical Sciences*, 67(2), 349-362.

Pan, F., Fan, T., Qi, X., Chen, J., and Zhang, C.(2021), Truck Scheduling for Cross-Docking of Fresh Produce with Repeated Loading, *Mathematical Problems in Engineering*, 2021, 5592122.

Rijal, A., Bijvank, M., and de Koster, R.(2019), Integrated Scheduling and Assignment of Trucks at Unit-Load Cross-Dock Terminals with Mixed Service Mode Dock Doors, *European Journal of Operational Research*, 278(3), 752-771.

Ropke, S. and Pisinger, D.(2006), An Adaptive Large Neighborhood Search Heuristic for the Pickup and Delivery Problem with Time Windows, *Transportation Science*, 40(4), 455-472.

Shahmardan, A. and Sajadieh, M. S.(2020), Truck Scheduling in a Multi-Door Cross-Docking Center with Partial Unloading: Reinforcement Learning-Based Simulated Annealing Approaches, *Computers & Industrial Engineering*, 139, 106134.

Theophilus, O., Dulebenets, M. A., Pasha, J., Lau, Y.-y., Fathollahi-Fard, A. M., and Mazaheri, A.(2021), Truck Scheduling Optimization at a Cold-Chain Cross-Docking Terminal with Product Perishability Considerations, *Computers & Industrial Engineering*, 156, 107240.

Van Belle, J., Valckenaers, P., and Cattrysse, D.(2012), Cross-Docking: State of the Art, *Omega*, 40(6), 827-846.

Van Belle, J., Valckenaers, P., Vanden Berghe, G., and Cattrysse, D.(2013), A Tabu Search Approach to the Truck Scheduling Problem with Multiple Docks and Time Windows, *Computers & Industrial Engineering*, 66(4), 818-826.

Watkins, C. J. C. H. and Dayan, P.(1992), Q-Learning, *Machine Learning*, 8, 279-292.

Xi, X., Liu, C., Wang, Y., and Lee, L. H.(2020), Two-Stage Conflict Robust Optimization Models for Cross-Dock Truck Scheduling Problem under Uncertainty, *Transportation Research Part E*, 144, 102123.